HAクラスタで PostgreSQLを高可用化 (後編) ~ レプリケーション編 ~ 2012年9月29日 しくみ+アプリケーション勉強会

松尾 隆利 NTT OSSセンタ





はじめに

- □今回は『HAクラスタでPostgreSQLを高可用化』の後編です
 - ストリーミングレプリケーション構成のクラスタリングのお話がメインです
 - 前編の入門編を復習されているのを前提にお話します。
 · http://linux-ha.sourceforge.jp/wp/wp-content/uploads/pacemaker_20120526JPUG.pdf
 - レプリケーション自体のお話も省きます。

開発経緯

□昔~昔・・・・

■ PostgreSQL 8.3 + 独自パッチで同期レプリケーション機能を実装し、 Heartbeat(Pacemakerの前身)でHAクラスタ化を実現するPG-REXというプロジェクトが あったそうな・・・

□2010年

- PostgreSQL 9.0 で非同期レプリケーション実装
 - → 同期レプリケーションを実現する独自パッチ + Pacemaker用RA開発でクラスタリング実現
- 9.0の非同期レプリケーションでも動くように手直しし、 Pacemakerコミュニティへ投稿 → リジェクト



□2011年

- PostgreSQL 9.1 で同期レプリケーション実装

 → 新たにPacemaker用RAを開発しクラスタリング実現
- Pacemakerコミュニティ意見も反映し投稿! → **絶賛!** (tremendous job!!)



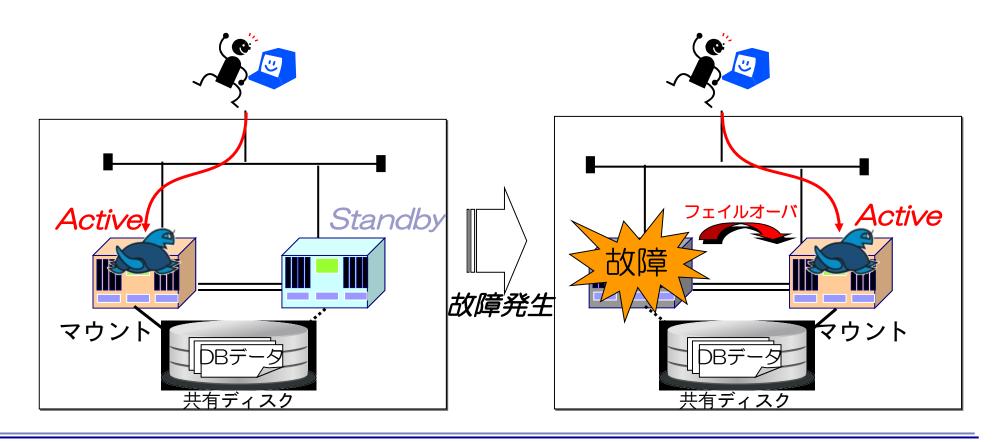
□2012年

- 4月13日 コミュニティのリポジトリにマージ
- 5月16日 resource-agents 3.9.3 として無事リリース ※Linux-HA Japan のリポジトリパッケージ **1.0.12-1.2** に同梱

前編の構成 ~Active/Standby 構成~



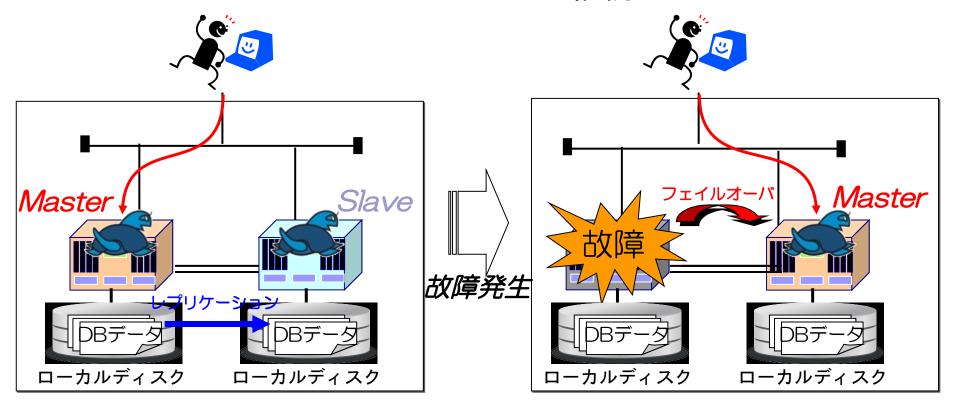
- PostgreSQLのデータは共有ディスク上に配置し、2台のサーバ間で共有
- 通常はActiveサーバでサービスを提供し、Activeサーバ故障時は StandbyサーバがActiveとなりサービスを提供



今回の構成 ~Master/Slave 構成~



- PostgreSQLのデータはそれぞれのサーバのローカルディスク上 に配置しPostgreSQLのストリーミングレプリケーション機能を 用いて共有
- □ 通常はMasterサーバでサービスを提供し、Masterサーバ故障時は SlaveサーバがMasterとなりサービスを継続



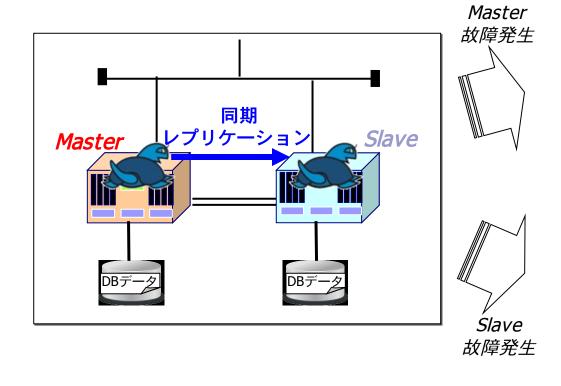
Active/Standby vs Master/Slave



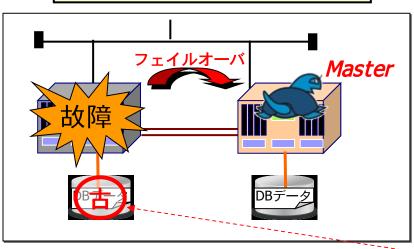
	Active/Standby	Master/Slave
ハードウェア費用	共有ディスク(相当のもの)必須	
運用のしやすさ	データは1箇所のみ	2箇所のデータの整合性を考慮
データの安全性	最新データは 共有ディスク上のみ	最新データは2箇所に分散
サービス継続性	プェイルオーバ時に リカバリに時間を要する	Slave故障がサービスに影響 (同期レプリケーション使用時)
DB性能	*************************************	共有ディスク構成をとれない 某高速ストレージを活用可
負荷分散	構成上不可能	ReadOnlyクエリを Slaveで処理可能
実績		これから・・・・

それぞれ一長一短。サービスの要件に応じて選択すること。

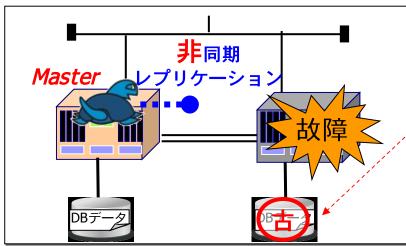
レプリケーション構成のHAクラスタ化 3大機能



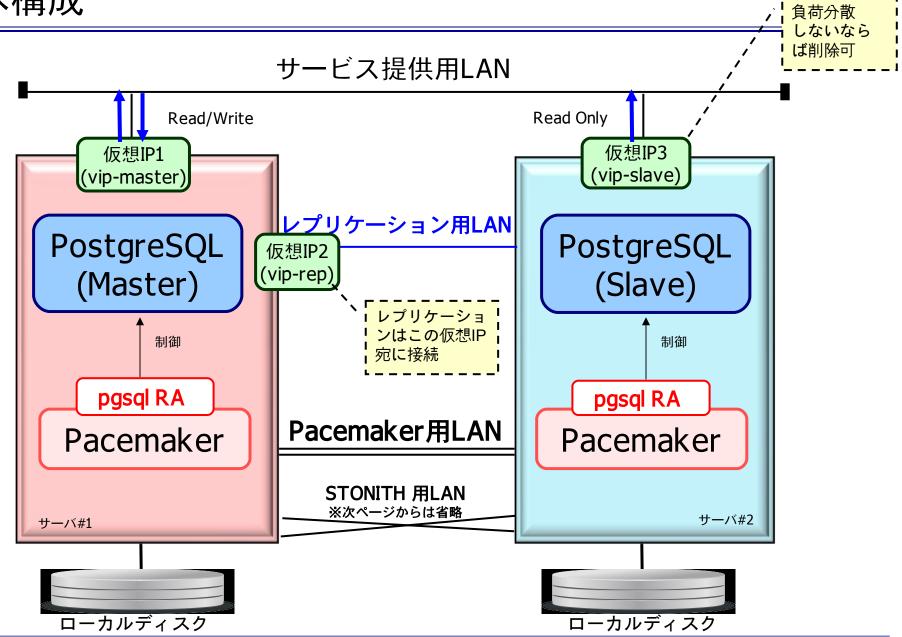
①フェイルオーバ



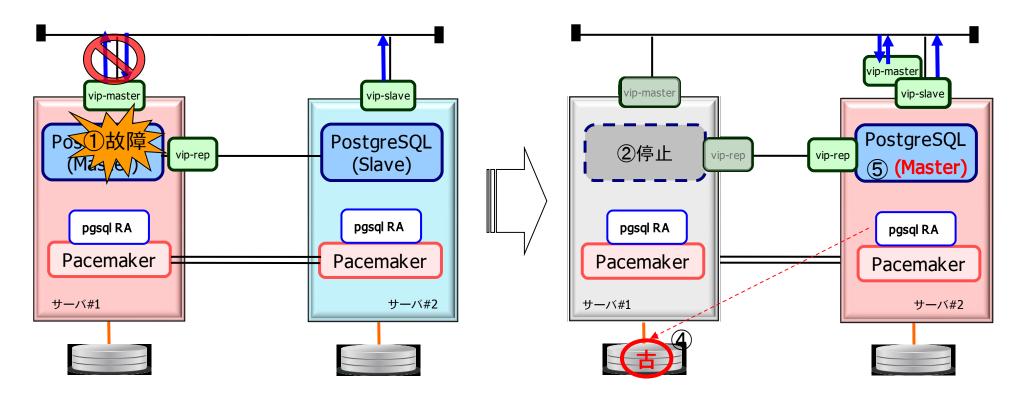
②同期・非同期の切替



基本構成



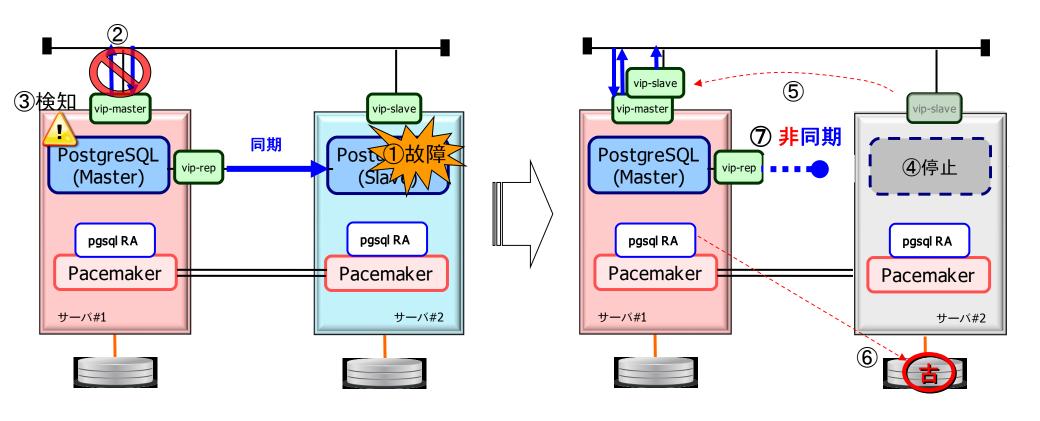
基本動作1: Masterのフェイルオーバ



① #1のPostgreSQLの故障を検知

- ② #1のPostgreSQLを停止
- ③ 仮想IP(vip-master, vip-rep, vip-slave)を停止
- ④ #1のデータが古いことを記録
- ⑤ #2のPostgreSQLをMasterに昇格(promote)
- ⑥ #2で仮想IP(vip-master, vip-rep, vip-slave) を起動

基本動作2:同期・非同期の切替



- ① Slaveの故障発生
- ② Masterのトランザクション停止
- ~ レプリケーションのタイムアウト待ち~
- ③ #1でレプリケーション切断を検知 SELECT * from pg_stat_replication

- ④ #2のPostgreSQLを停止
- ⑤ #2の仮想IP(vip-slave)を#1に付け替え
- ⑥ #2のデータが古いことを記録
- ⑦ #1のPostgreSQLを非同期に変更
 - → トランザクション再開

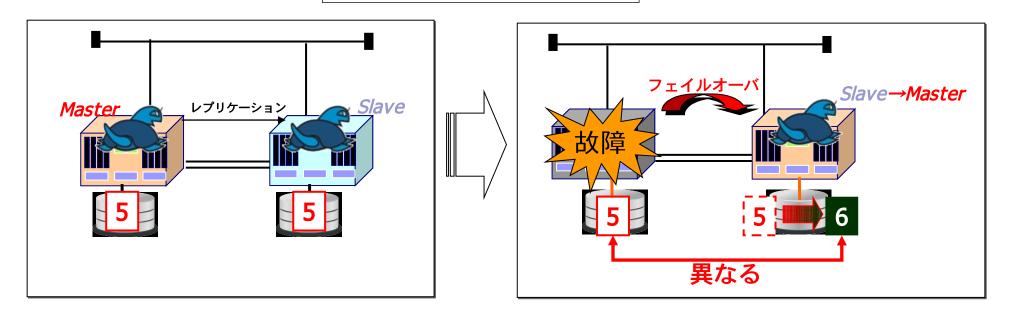
ここまでが基本動作 次はフェイルオーバ後の復旧

TimelineID



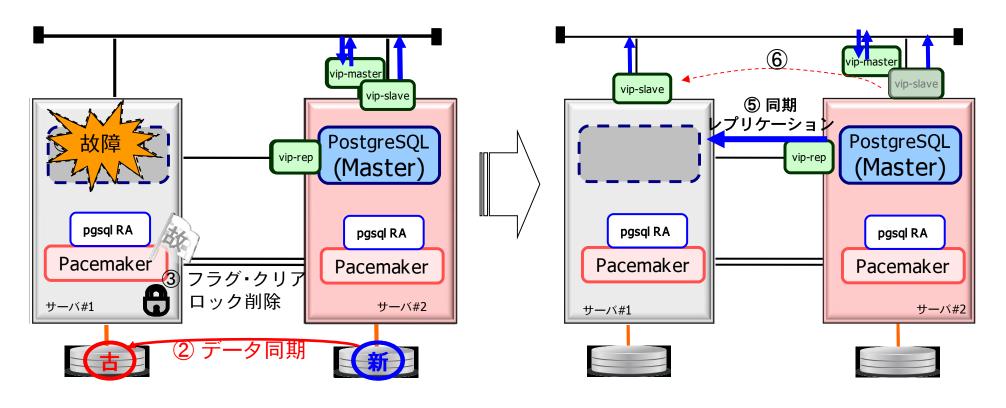
- PostgreSQLがSlaveからMasterへ昇格した際インクリメントされる数値
- □ TimelineIDが異なるとレプリケーション接続ができない

フェイルオーバ時



TimelineIDをそろえるには 新Masterのデータを旧Masterへコピーする必要あり

運用1: フェイルオーバ後の復旧



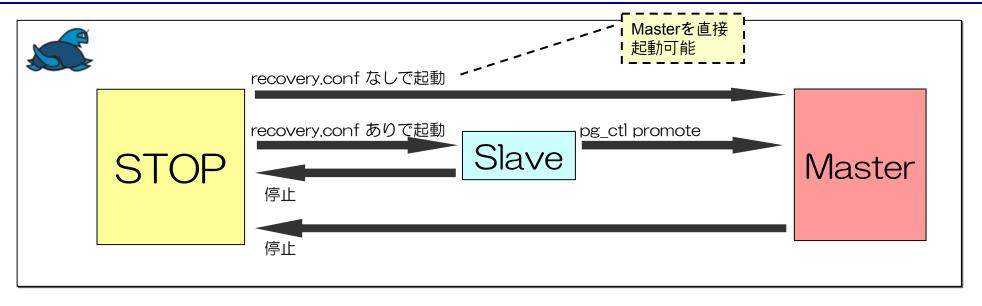
- (手動)

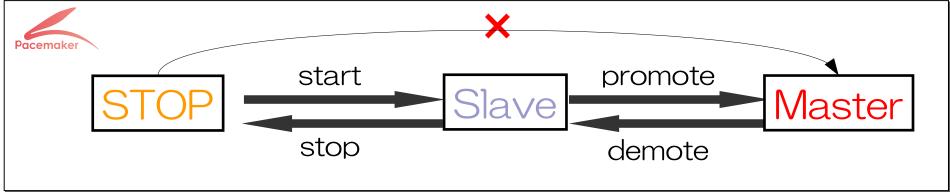
- ① 故障の復旧
- ② #1のデータを#2と同期→ TimelineIDがそろう
- ③ #1のロックファイル削除と Pacemaker上の故障フラグを クリア

- ④ #1のPostgreSQLをSlaveで起動
- ⑤ レプリケーション開始→ 非同期で接続→同期に切替
- ⑥ #2の仮想IP(vip-slave)を#1に付け替え

次は起動方法

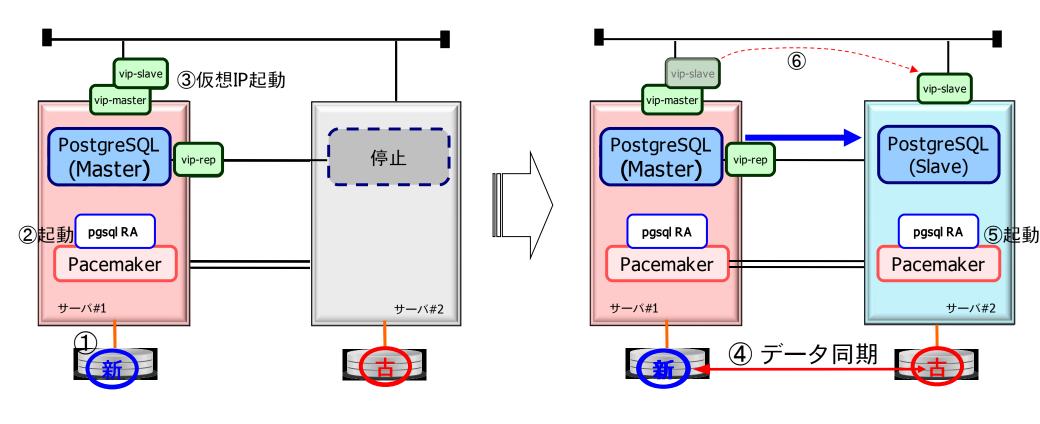
PostgreSQLとPacemakerの状態遷移





PostgreSQLのMasterは必ずSlaveを経由(recovery.confはRAが作成)して起動される
→ Master起動時もTimelinelDがインクリメントされる

運用2:起動



- ① データが新しい方のサーバーを選択
- ② 選択したサーバのPacemakerを起動
 - → Slaveで起動 → Masterに遷移
 - → TimelineIDがずれる
- ③ 仮想IPが#1で起動

- ④ #2のデータを#1と同期 → TimelineIDがそろう
 - ⑤ Pacemaker起動
 - → レプリケーション開始
 - ⑥ #1の仮想IP(vip-slave) を#2に付け替え

-- (手動)

ここからは状態遷移詳細

その前に用語を整理



PostgreSQLとPacemakerの状態遷移は一致しないため、 二者を区別するために以下を使い分け

□PostgreSQLの状態を表す用語

■ PRI : Primary(Master)状態

■ HS : Hot Standby(Slave)状態

■ STOP : 停止している状態

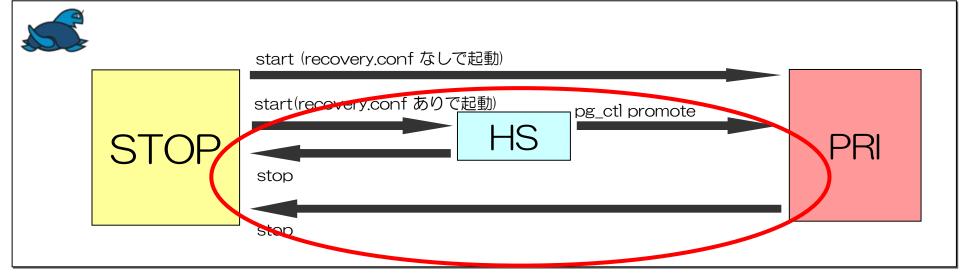
□Pacemakerの状態を表す用語

■ Master:アプリケーションをMasterとして管理している状態

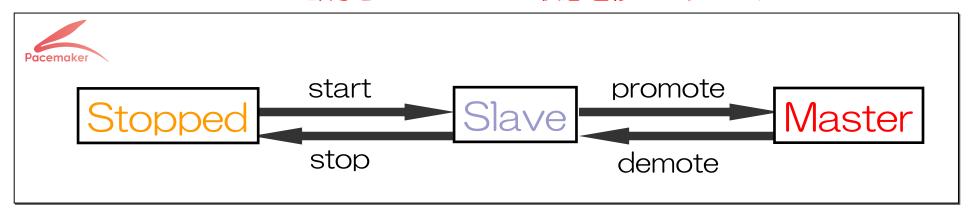
■ Slave : アプリケーションをSlaveとして管理している状態

■ Stopped: アプリケーションを停止として管理している状態

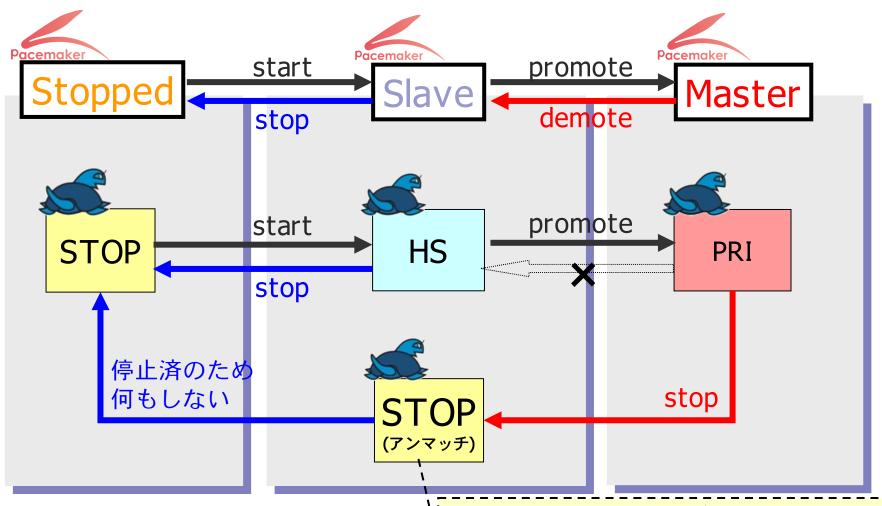
PostgreSQLとPacemakerの状態遷移 (用語区別版)



この部分をPacemakerの状態遷移とマッピング



状態遷移のマッピング



この状態はSlaveの監視が動くと故障となるためこの状態に留まることはできない。

HSの複数状態

- PostgreSQLのHSには複数の状態を管理
 - 1. PRI へ未接続

· · · HS:alone

- 2. PRI へ接続中
 - a. 同期レプリケーション以外 · · · HS:(others)
 - b. 同期レプリケーション中 · · · HS:sync

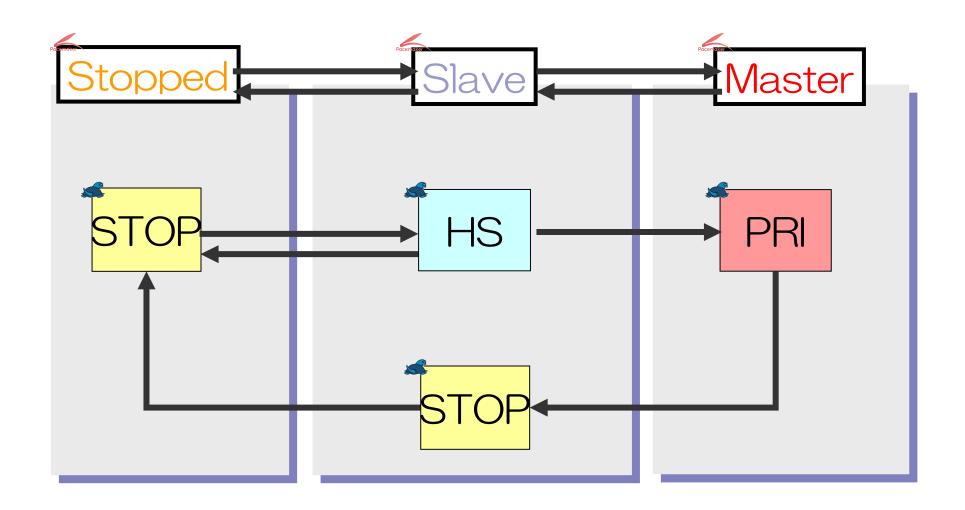
HS:(others) は以下の二つの状態をとる

- HS:connected
- HS:async

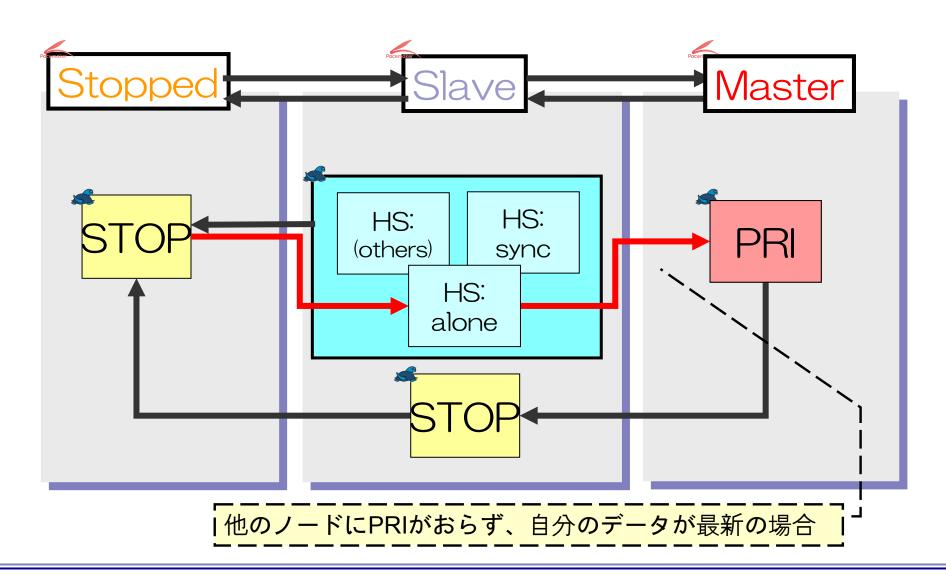
Pacemakerでこれら状態を"pgsql-status"属性として管理

※リソースID名をpgsqlとした場合

状態遷移のマッピング(改良前)



状態遷移のマッピング(改良後)



データの新旧判断方法

HSのデータが最新かどうかを判断する方法

- □PRI存在時
 - PRIとの接続状態を基にデータの状態を記録
 - · PRI存在時は自分がPRIに昇格することはないため記録のみ
- □PRI故障時
 - PRI故障直前のPRIとの接続状態を基に判断
- □初期起動時 (PRIが一度も存在したことがない時)
 - 他にHSがいる場合
 - ・ 他のHS間でデータの新旧を比較して判断
 - 他にHSがいない場合
 - ・ 自分が最新だと判断

データの状態

□ PRI存在時に記録するHSのデータ状態

1. PRI へ未接続

-- DISCONNECT

- 2. PRI へ接続中
 - a. 同期レプリケーション以外・・ STREAMING ASYNC (例)
 - b. 同期レプリケーション中 · STREAMING|SYNC

最新データ

古いデータ

※ pg_stat_replication ビューから取得

□ PRI時

· · LATEST

Pacemakerでこれら状態を"pgsql-data-status"属性として管理

※リソースID名をpgsqlとした場合

pgsql-status と pgsql-data-status 属性の違い

□ pgsql-status

■ PostgreSQL の現在の実行状態を示す

· 停止 : STOP

・ HSで動作 : HS:alone, HS:async, HS:sync

· PRIで動作 : PRI

· 不明時 : UNKNOWN

用途

用途

・HSの現在の状態把握

・データの新旧状態記録

・Masterへの昇格可否の判断

・HSの状態と他のリソースとの連携



□ pgsql-data-status

■ PRI との関係によって決まるデータの状態。

· PRI未接続時 : DISCONNECTED

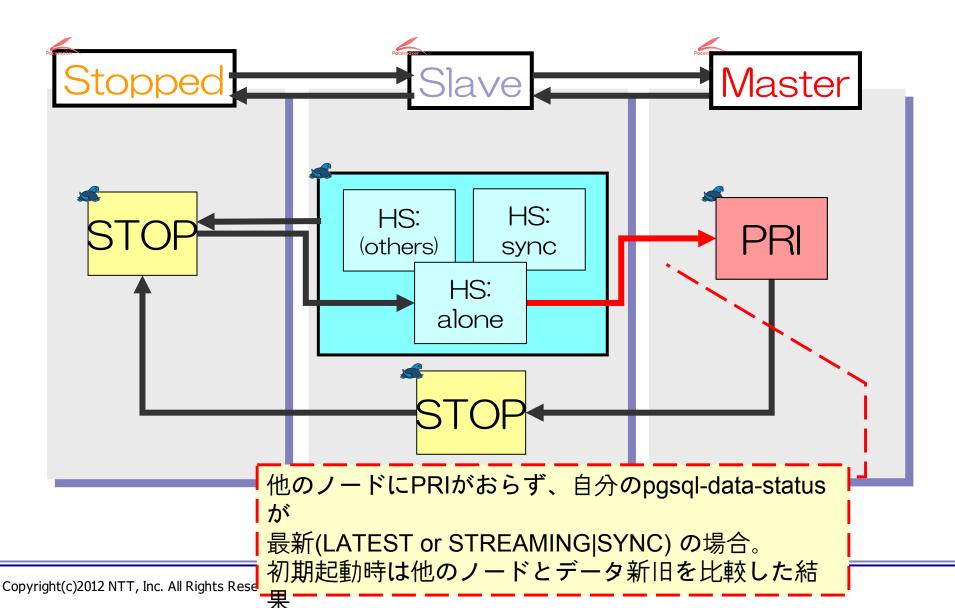
· HS時 : STREAMING|ASYNC, STREAMING|SYNC 等

· PRI時 : LATEST

- PRI 故障時、PRI故障直前の状態が残る
 - · PostgreSQL の実行状態と必ずしも一致しない
 - pgsql-status=HS:aloneで、pgsql-data-status = LATEST があり得る

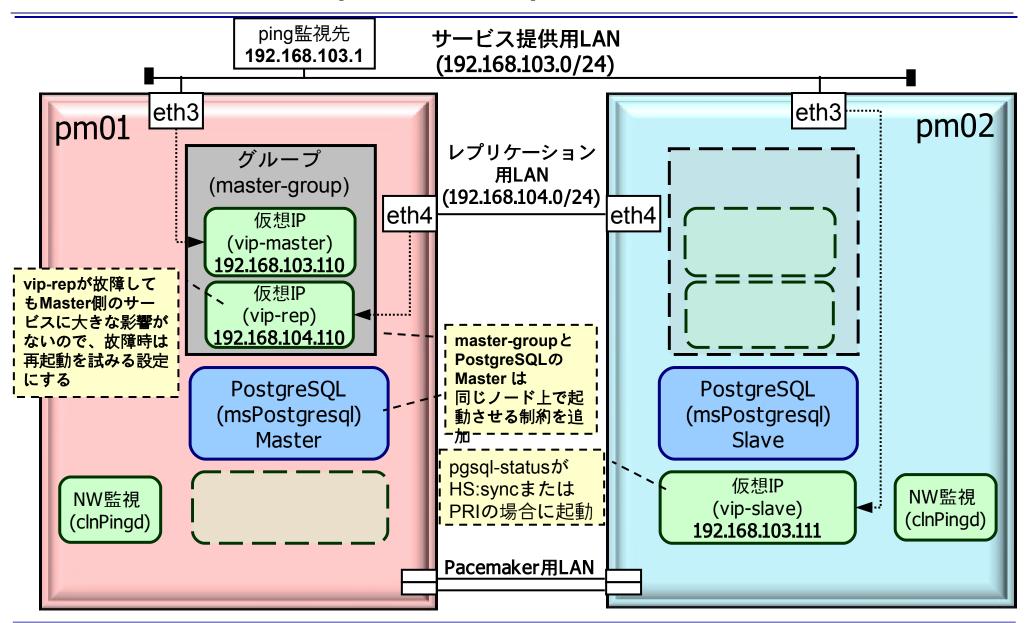


状態遷移のマッピング (条件整理後)



Pacemakerの設定例

リソース構成例 (シンプル版)



Pacemaker 設定例 (シンプル版) 1/2

```
property \
  no-quorum-policy="ignore" \
  stonith-enabled="false" \
  crmd-transition-delay="0s"
rsc_defaults \
  resource-stickiness="INFINITY" \
  migration-threshold="1"
                               PostgreSQL Ø
ms msPostgresql pgsql \
  meta \
                           Master/Slave化設定
    master-max="1" \
    master-node-max="1" \
   clone-max="2" \
    clone-node-max="1" \
   notify="true"
                            サービス用仮想IPと
group master-group \
  vip-master \
                           レプリケーション用仮想IPを
  vip-rep \
  meta \
                        master-groupとしてグループ化
   ordered="false"
clone clnPingd \
  pingCheck
primitive vip-master ocf:heartbeat:IPaddr2 \ ◆ サービス用
  params \
                                 仮想IP(vip-master)設定
   ip="192.168.103.110" \
    nic="eth3" \
    cidr netmask="24" \
  op start timeout="60s" interval="0s" on-fail="restart" \
  op monitor timeout="60s" interval="10s" on-fail="restart" \
  op stop timeout="60s" interval="0s" on-fail="block"
```

設定詳細は字が小さくて見えないと思うので、 資料アップロード後確認してください

```
primitive vip-rep ocf:heartbeat:IPaddr2 \
                                                レプリケーション用
  params \
                                               仮想IP(vip-rep)設定
    ip="192.168.104.110" \
    nic="eth4" \
    cidr netmask="24" \
  meta \
    migration-threshold="0" \
  op start timeout="60s" interval="0s" on-fail="stop" \
  op monitor timeout="60s" interval="10s" on-fail="restart" \
  op stop timeout="60s" interval="0s" on-fail="block"
                                                    HS (read only) 用
primitive vip-slave ocf:heartbeat:IPaddr2 \
  params \
                                                  仮想IP(vip-slave)設定
    ip="192.168.103.111" \
    nic="eth3" \
    cidr netmask="24" \
  meta \
    resource-stickiness="1" \
  op start timeout="60s" interval="0s" on-fail="restart" \
  op monitor timeout="60s" interval="10s" on-fail="restart" \
  op stop timeout="60s" interval="0s" on-fail="block"
primitive pgsgl ocf:heartbeat:pgsgl \
  params \
                                                                     PostgreSQL
    pgctl="/usr/pgsql-9.1/bin/pg ctl" \
    psql="/usr/pqsql-9.1/bin/psql" \
                                                                       メイン設定
    pgdata="/var/lib/pgsql/9.1/data/" \
    rep mode="sync" \
    node list="pm01 pm02" \
    restore_command="cp /var/lib/pgsql/9.1/data/pg_archive/%f %p" \
      primary conninfo opt="keepalives idle=60 \
                        keepalives interval=5 keepalives count=5" \
    master_ip="192.168.104.110" \
    stop escalate="0" \
  op start timeout="30s" interval="0s" on-fail="restart" \
  op stop timeout="30s" interval="0s" on-fail="block" \
  op monitor timeout="30s" interval="11s" on-fail="restart" \
  op monitor timeout="30s" interval="10s" on-fail="restart" role="Master" \
  op promote timeout="30s" interval="0s" on-fail="restart" \
  op demote timeout="30s" interval="0s" on-fail="block" \
  op notify timeout="60s" interval="0s"
```

Pacemaker 設定例 (シンプル版) 2/2

```
primitive pingCheck ocf:pacemaker:pingd \
  params \
    name="default ping set" \
    host list="192.168.103.1" \
    multiplier="100" \
  op start timeout="60s" interval="0s" on-fail="restart" \
  op monitor timeout="60s" interval="2s" on-fail="restart" \
  op stop timeout="60s" interval="0s" on-fail="ignore"
### Resource Location ###
location rsc location-1 msPostgresql \
  rule -inf: not defined default ping set or default ping set It 100
location rsc location-2 vip-slave \
                                                             HS (read only) 用仮想IP (vip-slave)
  rule 200: pgsgl-status eg HS:sync \
 rule 100: pgsgl-status eg PRI \
                                                                          起動条件の設定
  rule -inf: not defined pgsql-status \
  rule -inf: pgsgl-status ne HS:sync and pgsgl-status ne PRI
### Resource Colocation ###
colocation rsc colocation-1 inf: msPostgresql
                                            clnPingd
                                           colocation rsc colocation-2 inf: master-group
### Resource Order ###
order rsc order-1 0: clnPingd
                                 msPostgresgl
                                                 symmetrical=false
order rsc order-2 inf: msPostgresgl:promote master-group:start symmetrical=false
                                                                            ├ Masterと仮想IPの起動・停止順番設定
order rsc order-3 0: msPostgresql:demote master-group:stop symmetrical=false
```

商用利用時は、STONITHやディスク監視等、 その他必要なリソースは別途追加すること

重要な点だけピックアップ

PostgreSQLメイン設定部 ~pgsql RA~

```
primitive pgsql ocf:heartbeat:pgsql ¥
   params ¥
      pgctl="/usr/pgsql-9.1/bin/pg_ctl" \u224
      psql="/usr/pgsql-9.1/bin/psql" \frac{1}{2}
                                            ・ 各コマンドやPostgreSQLデータの場所を指定
      pgdata="/var/lib/pgsql/9.1/data/" ¥
       rep_mode="sync" \( \)
                                      同期レプリケーション使用 (指定しない場合は通常のAct-Stadby動作)
       レプリケーションに参加するサーバーの全ホスト名
                                                                        recovery.conf O
      restore_command="cp /var/lib/pgsql/9.1/data/pg_archive/%f %p" ¥ ← restore_command 設定
      primary_conninfo_opt="keepalives_idle=60 ¥
                                                                    recovery.conf@
                        keepalives_interval=5 keepalives_count=5" ¥
                                                                ├ primary_conninfo /こ
      master_ip="192.168.104.110" ¥ ← vip-rep ⊘IP
      op start timeout="30s" interval="0s" on-fail="restart" \frac{1}{2}
   op stop timeout="30s" interval="0s" on-fail="block" \frac{1}{2}
   op monitor timeout="30s" interval="11s" on-fail="restart" \frac{1}{2}
   op monitor timeout="30s" interval="10s" on-fail="restart" role="Master" ¥
                                                                         monitor(Master時)
   op promote timeout="30s" interval="0s" on-fail="restart" \frac{1}{2}
                                                                         promote, demote
   op demote timeout="30s" interval="0s" on-fail="block" \frac{1}{2}
                                                                         notifyの動作定義
   op notify timeout="60s" interval="0s"
```

仮想IP vip-slave (ReadOnly用) の起動条件設定部

HS:syncの方がスコアが大きい (200 > 100)ため、 正常な同期レプリケーション時はSlave側で、 それ以外はPRI (Master)側で起動。

```
※vip-slaveが起動するノードが固定されないように、resource-stickinessは"1"にしておくこへと
```

```
primitive vip-slave ocf:heartbeat:IPaddr2 \
    params \
    ip="192.168.103.111" \
    nic="eth3" \
    cidr_netmask="24" \
    meta \
    resource-stickiness="1" \
```

仮想IP vip-rep (レプリケーション用) の再起動設定

```
primitive vip-rep ocf:heartbeat:IPaddr2 \
  params \
    ip="192.168.104.110" \
    nic="eth4" \
    cidr netmask="24" \
  meta \
    migration-threshold="0"
  op start timeout="60s" interval="0s" on-fail="stop" \
  op monitor timeout="60s" interval="10s" on-fail="restart" \
  op stop timeout="60s" interval="0s" on-fail="block"
```

```
レプリケーション用仮想IPは、監視で故障発生しても
再起動を試みる設定にする
※0は回数制限なし
```

Masterと仮想IP(vip-master, vip-rep)の起動・停止順番設定部

promote 後に 仮想IP を起動

order rsc_order-2 inf: msPostgresql:promote <u>master-group:</u>start symmetrical=false 仮想IPを含むグループ

order rsc_order-3 0: _msPostgresql:demote master-group:stop symmetrical=false

demote(PostgreSQL停止)完了後に仮想IPを停止。 先に仮想IPを停止すると、レプリケーション接続が切断され、 レプリケーションのパケットが届かなくなるのを防ぐため先にdemote する。

同期レプリケーション時のPacemaker表示例 (crm_mon -Af)

```
Online: [ pm01 pm02 ]
vip-slave (ocf::heartbeat:IPaddr2):
                                          Started pm02
                                                                        仮想IPの
Resource Group: master-group
    vip-master (ocf::heartbeat:IPaddr2):
                                          Started pm01
                                                                           状態
    vip-rep (ocf::heartbeat:IPaddr2):
                                         Started pm01
Master/Slave Set: msPostgresql
    Masters: [pm01]
                                                                           PostgreSQL 0
    Slaves: [ pm02 ] ______
                                                                         Master/Slaveの状態
Clone Set: clnPingd
    Started: [pm01 pm02]
Node Attributes:
* Node pm01:
                                                                         pm01ノードの
                                   : 100
   + default_ping_set
                                                                         pgsql-status,
                                   : 1000 ._____
   + master-pgsql:0
   + pgsql-data-status
                                   : LATEST
                                                                         pgsql-data-status
   + pgsql-status
                                   : PRI
                                                                          の状態
   + pgsql-master-baseline
                                   : 0000000150000B0
   + pm02-eth1
                                   : up
                                                                         promote直前のxlogの位置
   + pm02-eth2
                                   : up
* Node pm02:
   + default_ping_set
                                   : 100
                                                                         pm02ノードの
                                   : 100
   + master-pgsql:1
                                                                         pgsql-status,
                                   : STREAMING | SYNC
   + pgsql-data-status
                                                                          pgsql-data-status
   + pgsql-status
                                   : HS:sync
   + pm01-eth1
                                                                          の状態
                                   : up
   + pm01-eth2
                                   : up
Migration summary:
* Node pm01:
```

* Node pm02:

PostgreSQLの設定ポイント

postgresql.conf (重要点のみ)

- □ listen_address = *
 - Slaveには仮想IP(vip-master)が存在しないため特定IPでListenはできない
- □ synchronous_standby_names はコメントアウト
 - Pacemakerが同期・非同期を切り替えるためユーザ設定不可
 - ・RAが/var/lib/pgsql/tmp/rep_mode.conf をincludeする設定を自動追加
- □ restart_after_crash = off
 - PacemakerがPostgreSQLの状態管理をするため、自動再起動はoff
- □ replication_timeout = 20s (ぐらい?)
 - 誤検知しない程度に短くする。Slave故障時にMasterのトランザクションが 止まる時間に影響
- □ hot_standby = on
 - Slaveを監視するために必須
- max_standby_streaming_delay = -1
 max_standby_archive_delay = -1
 - Slaveの監視クエリがキャンセルされるのを防ぐ

postgresql.conf (その他)

- □ wal_level = hot_standby
- ■wal_keep_segments = 64 (ぐらい?)
 - 小さくし過ぎると、レプリケーションに必要なwalがすぐに 削除されてしまう
- ■wal_receiver_status_interval = 5s (ぐらい?)
 - replication_timeout より短くすること
- □hot_standby_feedback = on
- □archive_mode = on

ロックファイル

ロックファイル



□PRIを停止すると残るファイル

- データ不整合を避けるために導入
 - 本ファイルが存在するとPostgreSQLは起動できない
 - ・デフォルトパス:/var/lib/pgsql/tmp/PGSQL.lock
- HSがいない場合、PRI正常停止時に削除される

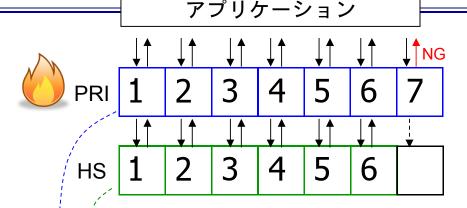
★同期レプリケーションの意味★

- コミット成功は必ず両サーバにデータが存在することを保証
- → つまりコミット失敗時はデータがコミットされたかどうかは不定
- → 最悪両サーバ間でデータに差異が発生
- → PostgreSQLはこの差異を検知できないため起動をロック

不整合の発生パターン例

□問題が発生するパターン

- PRIに7のデータ書き込み
- PRIが7のデータをHSへ転送中に PRIが故障 (HSにパケット未達)



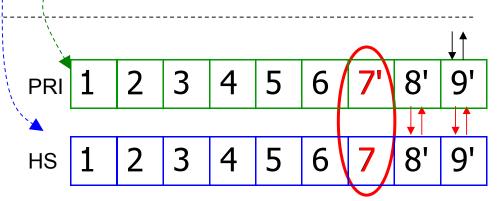
3

HS[^]

PRI

- フェイルオーバ発生
 - HSは6までのデータでPRIに昇格し7', 8'のデータを書き込み

- 旧PRIをHSとして組み込み
 - ・ 旧PRIには転送し損ねた7のデータが 存在するため、8'からレプリケーション が開始される



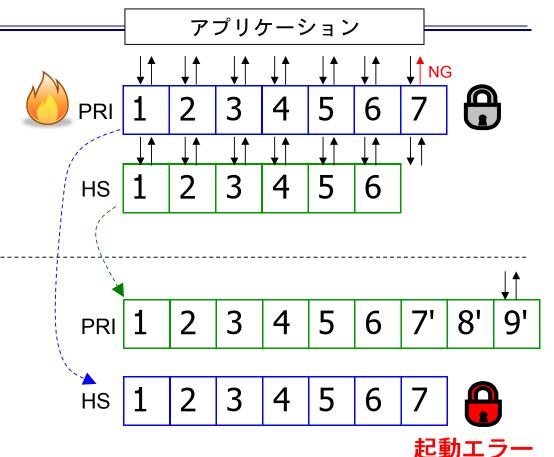
5

6

不整合発生

ロックファイル導入後

- □ 回避パターン
 - PRI へ昇格時にロックファイル作成
 - PRIに7のデータ書き込み
 - PRIが7のデータをHSへ転送中に
 PRIが故障 (HSにパケット未達)
 → フェイルオーバ発生 (図省略)
 - IHPRIをHSとして組み込み
 - → HS起動時にロックファイルが あるため起動エラーに。



ロックファイルがある場合は、新PRIのデータを新HSへコピーし ロックファイルを削除する手順が必要

HAクラスタ化まとめ

- □ 3大機能
 - Masterのフェイルオーバ
 - レプリケーションの同期・非同期の切替
 - データの状態管理
- □ Pacemaker設定のポイント
 - レプリケーション用の仮想IP(vip-rep)が必要
 - 必要ならばSlaveにReadOnlyクエリ負荷分散用仮想IPを設定可能
- □運用時の注意
 - TimelineIDがずれているとレプリケーションできないため注意
 - フェイルオーバ後はTimelineIDのずれに加えデータ不整合も発生する可能性あり ・ ロックファイルがある場合、不整合が発生していないデータに入れ替えること

動作環境

- □Pacemaker 1.0.12 以上推奨
 - 1.0.11だとMaster/Slaveバグ回避設定が必要
- □resource-agents 3.9.3 以上
 - Linux-HA Japan Pacemakerリポジトリパッケージ **1.0.12 1.2** 以上に同梱 (2012年7月リリース)
 - 色々バグフィックスしているので、pgsql RAだけ最新に入れ替えた方が無難
- □PostgreSQL 9.1 以上
 - 9.0では動きません
 - 9.2では動いたとの報告あり

参考

- □ソースコード (GitHub上のRA直リンク)
 - URL: https://github.com/ClusterLabs/resource-agents/blob/master/heartbeat/pgsql
- □ドキュメントおよび設定例 (GitHubのWiki)
 - https://github.com/t-matsuo/resource-agents/wiki/
- □Pacemakerダウンロード・インストール
 - http://linux-ha.sourceforge.jp/