

---

# OpenStackでも重要な役割を果たす Pacemakerを知ろう！

～クラウドの雲の下では何が起きているのか～



2016年11月5日  
Linux-HA Japan プロジェクト  
<http://linux-ha.osdn.jp/>  
森 啓介

- 名前: 森 啓介 (Keisuke MORI)

- twitter: @ksk\_ha

- Linux-HA Japanプロジェクト関連の活動

- Pacemakerリポジトリパッケージのリリース

- <http://linux-ha.osdn.jp/>

- ClusterLabs プロジェクトのコミット

- Pacemaker、resource-agents などHAクラスタ関連の開発コミュニティ

- <https://github.com/ClusterLabs/>

- 本業

- 普段の業務: NTT OSSセンタ

- NTTグループ内におけるPacemaker/Heartbeatの導入支援・サポート

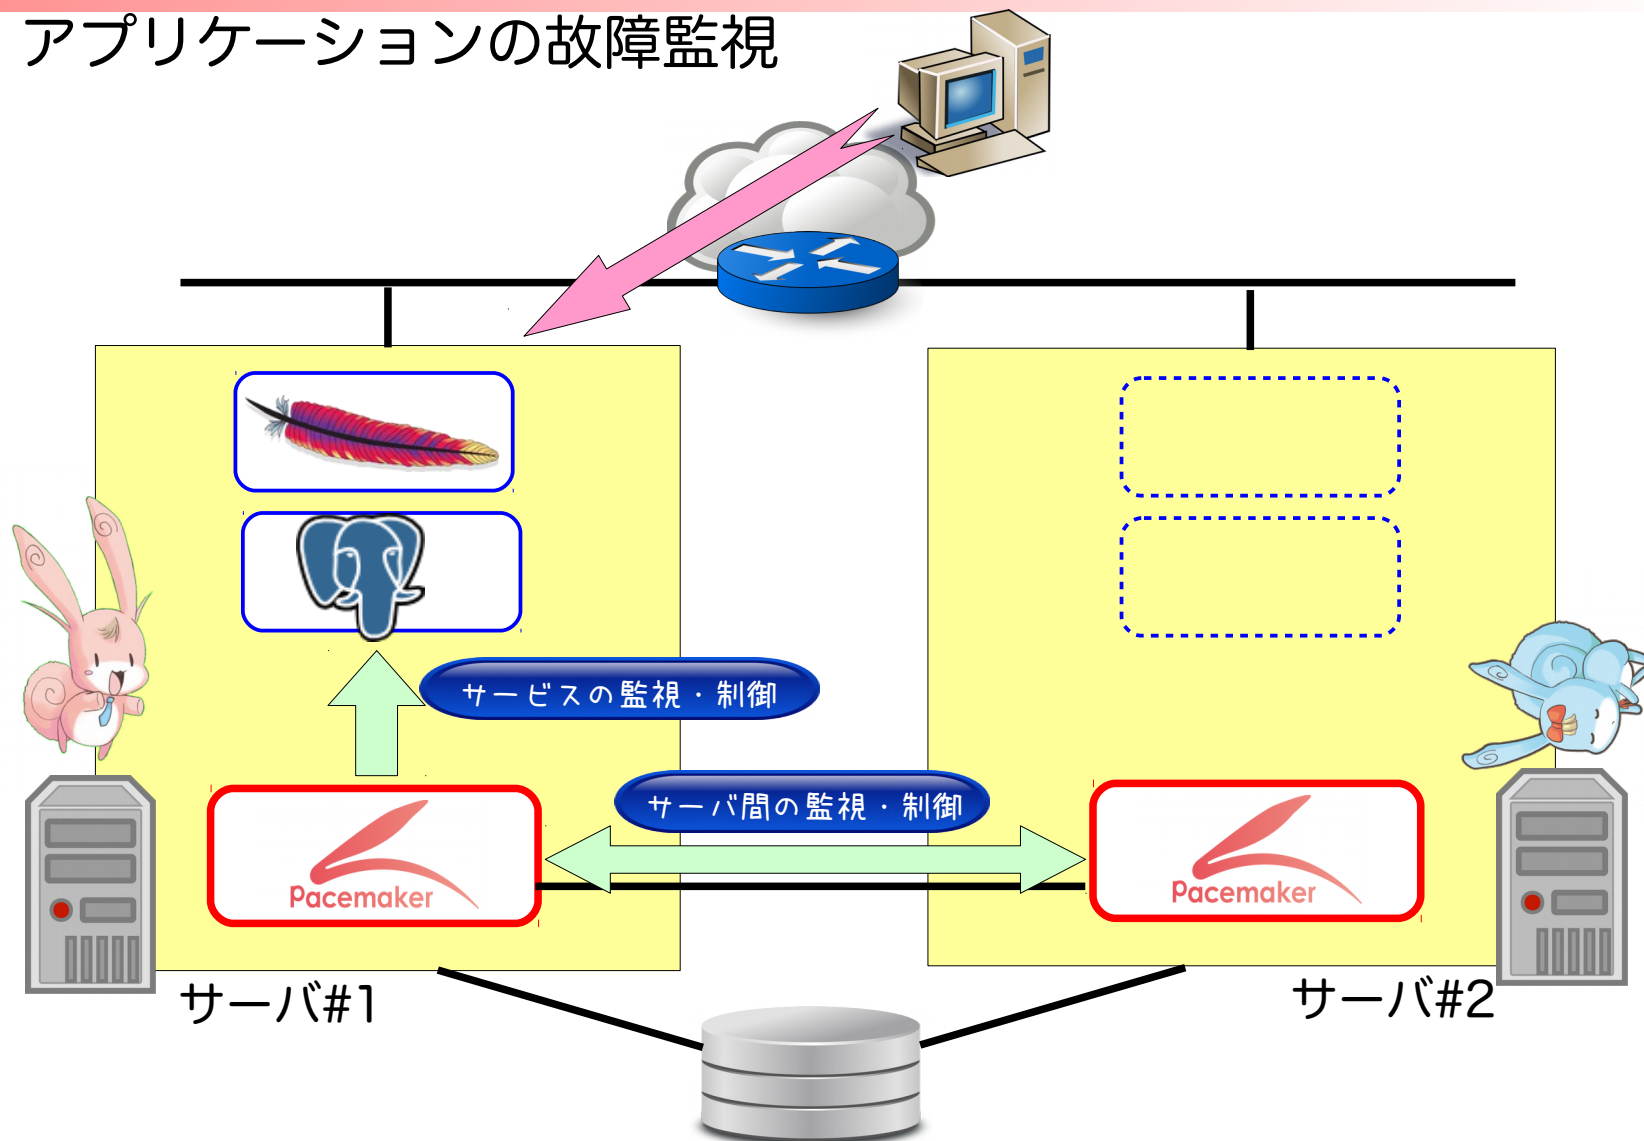
- バグ報告・パッチ作成などによるNTTから開発コミュニティへのフィードバック・貢献

- Pacemakerとは
- OpenStack におけるHAの必要性
- Red Hat OpenStack Platform でのHA構成例
- OpenStack HA の今後の動向

- Pacemakerとは
- OpenStack におけるHAの必要性
- Red Hat OpenStack Platform でのHA構成例
- OpenStack HA の今後の動向


# Pacemakerの概要

## ■ サーバ・アプリケーションの故障監視



# Pacemakerの概要

- 故障検知時、自動的にフェイルオーバー
- ダウンタイムの最小化
- STONITHによるデータの安全性確保



# Pacemakerを詳しく知りたかったら…



## Pacemaker 応援キャラクター



Pacemakerとは… 高可用(HA)クラスタソフトウェアです。

Linux-HA Japan プロジェクト 2F 205教室にてデモ展示中！

- Pacemakerとは

- OpenStack におけるHAの必要性

- Red Hat OpenStack Platform でのHA構成例

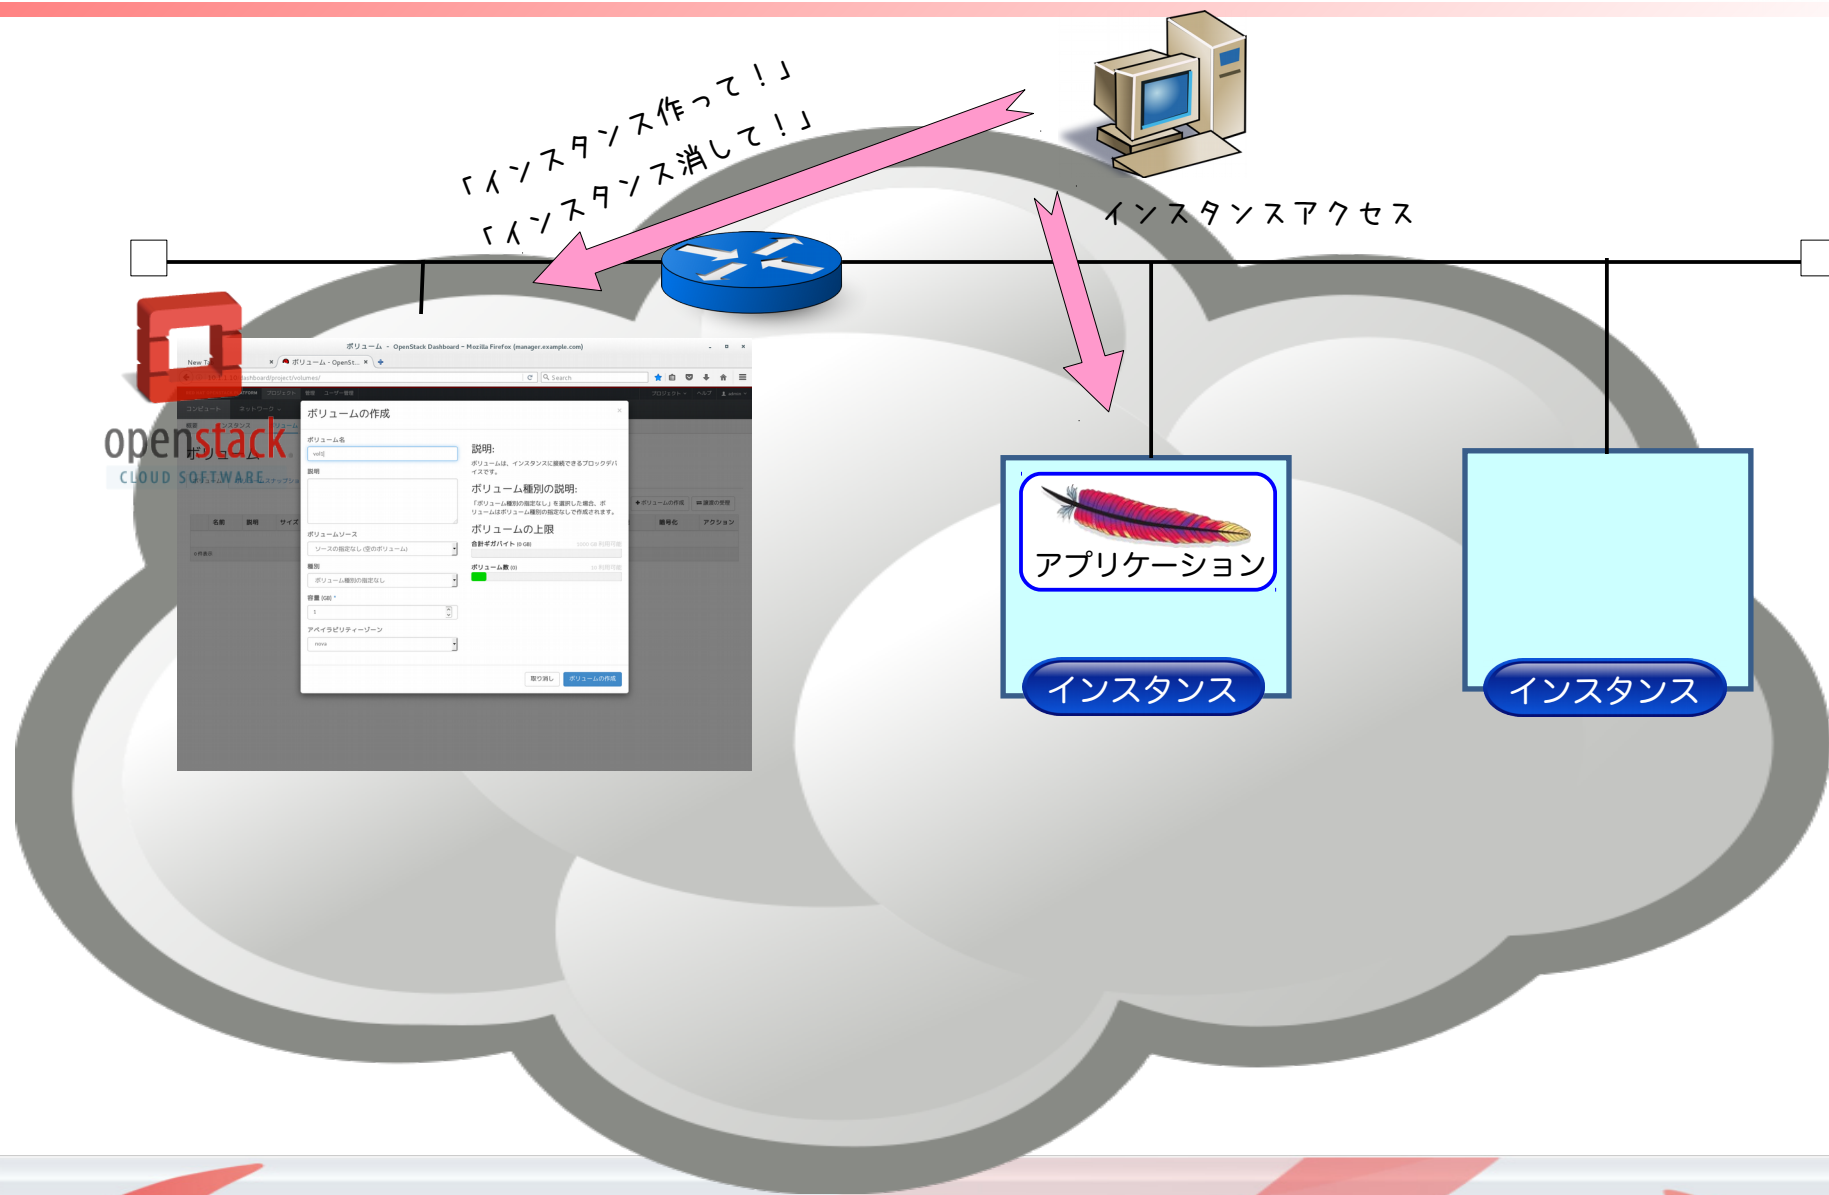
- OpenStack HA の今後の動向



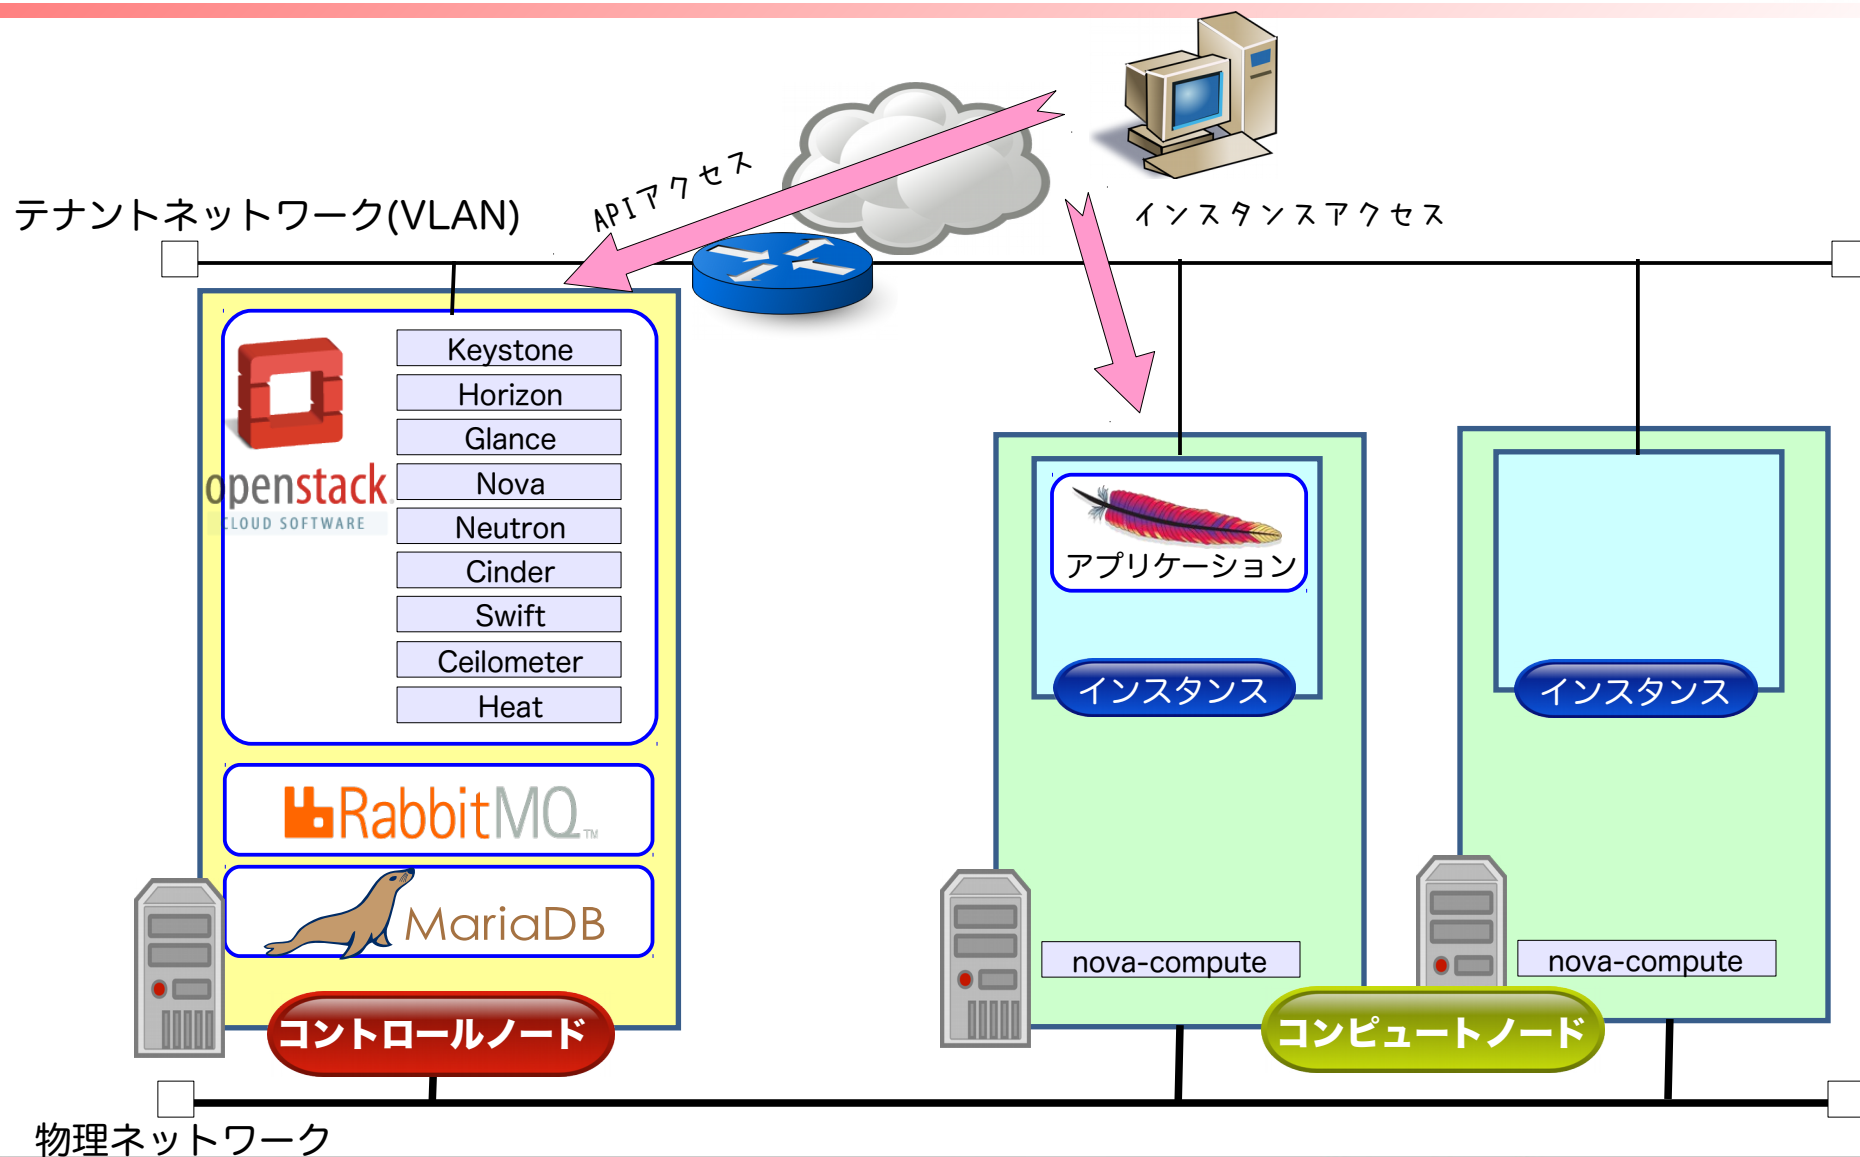


クラウド時代にHAクラスタなんて  
いるのお??

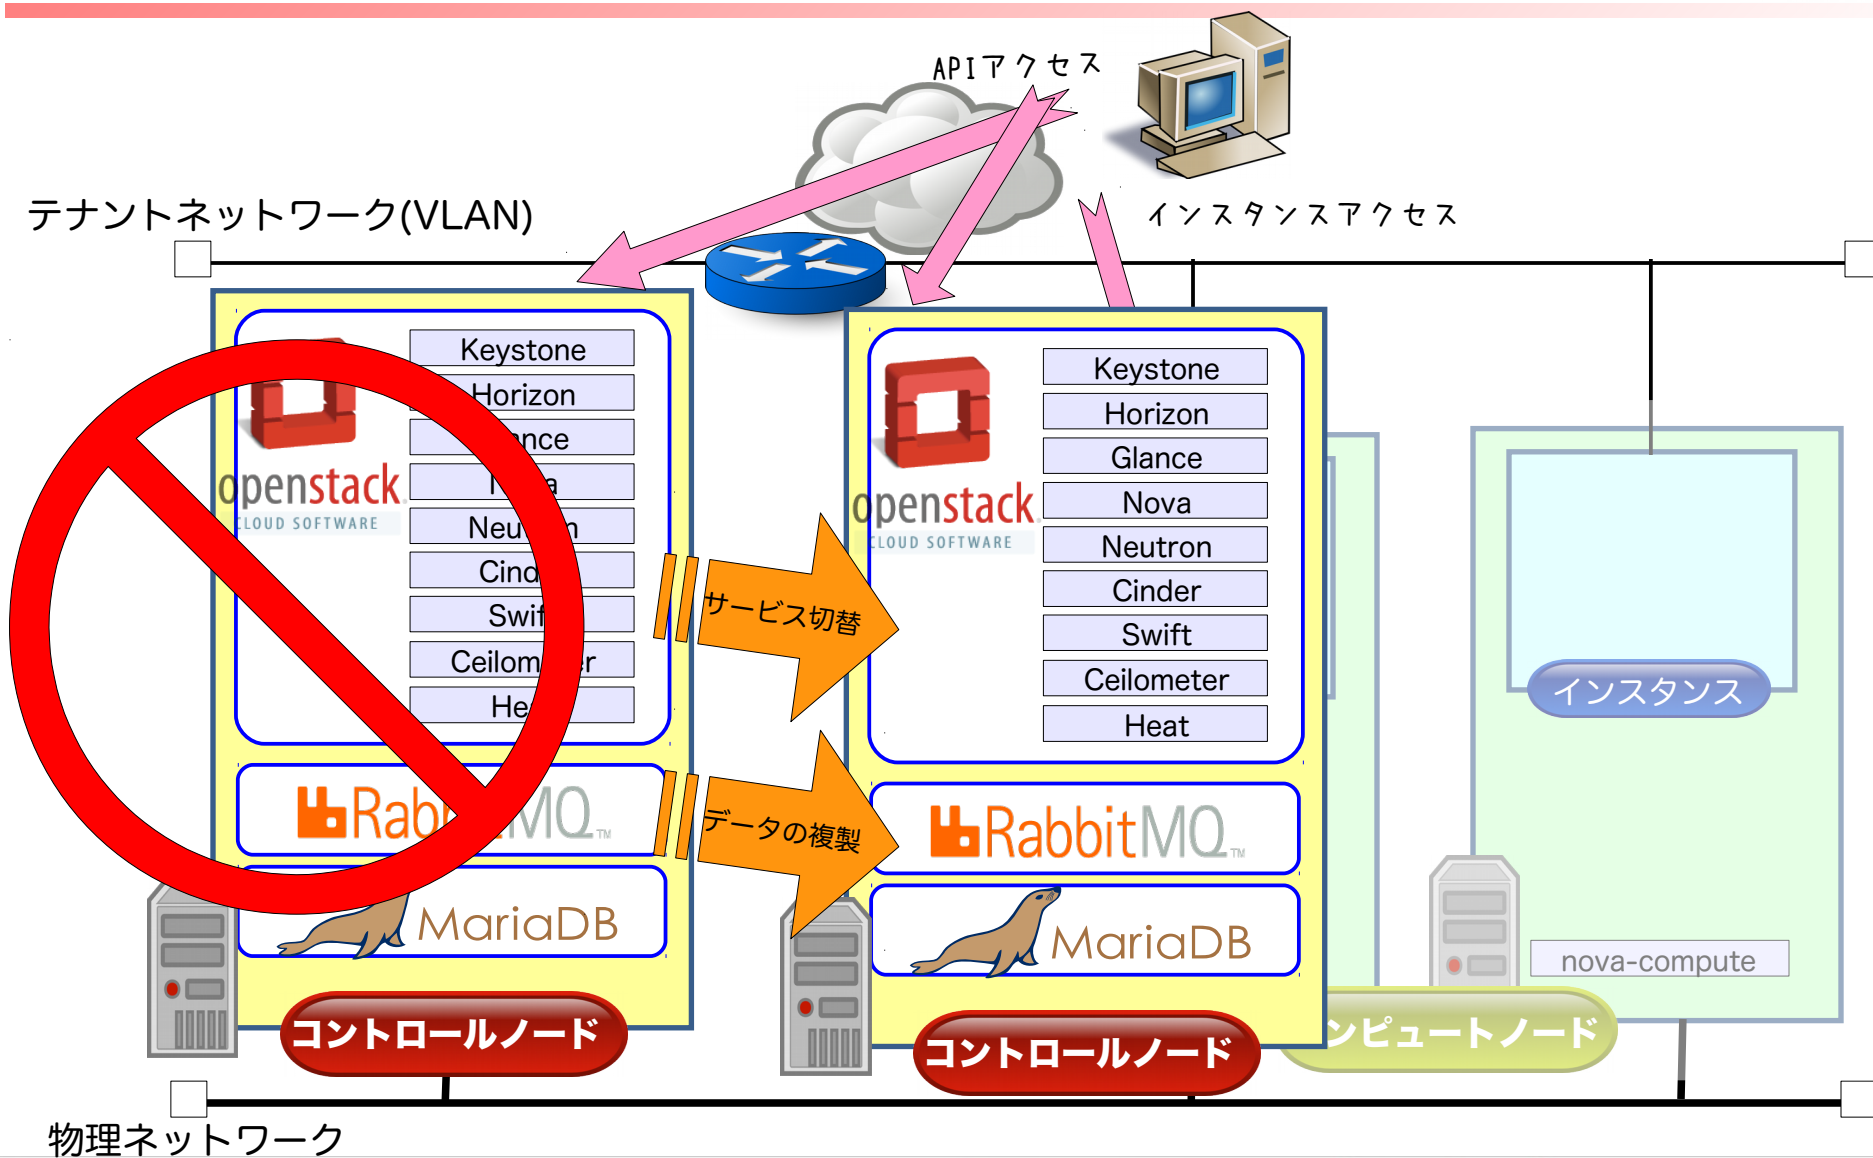
# クラウドユーザ(テナント)からみた世界



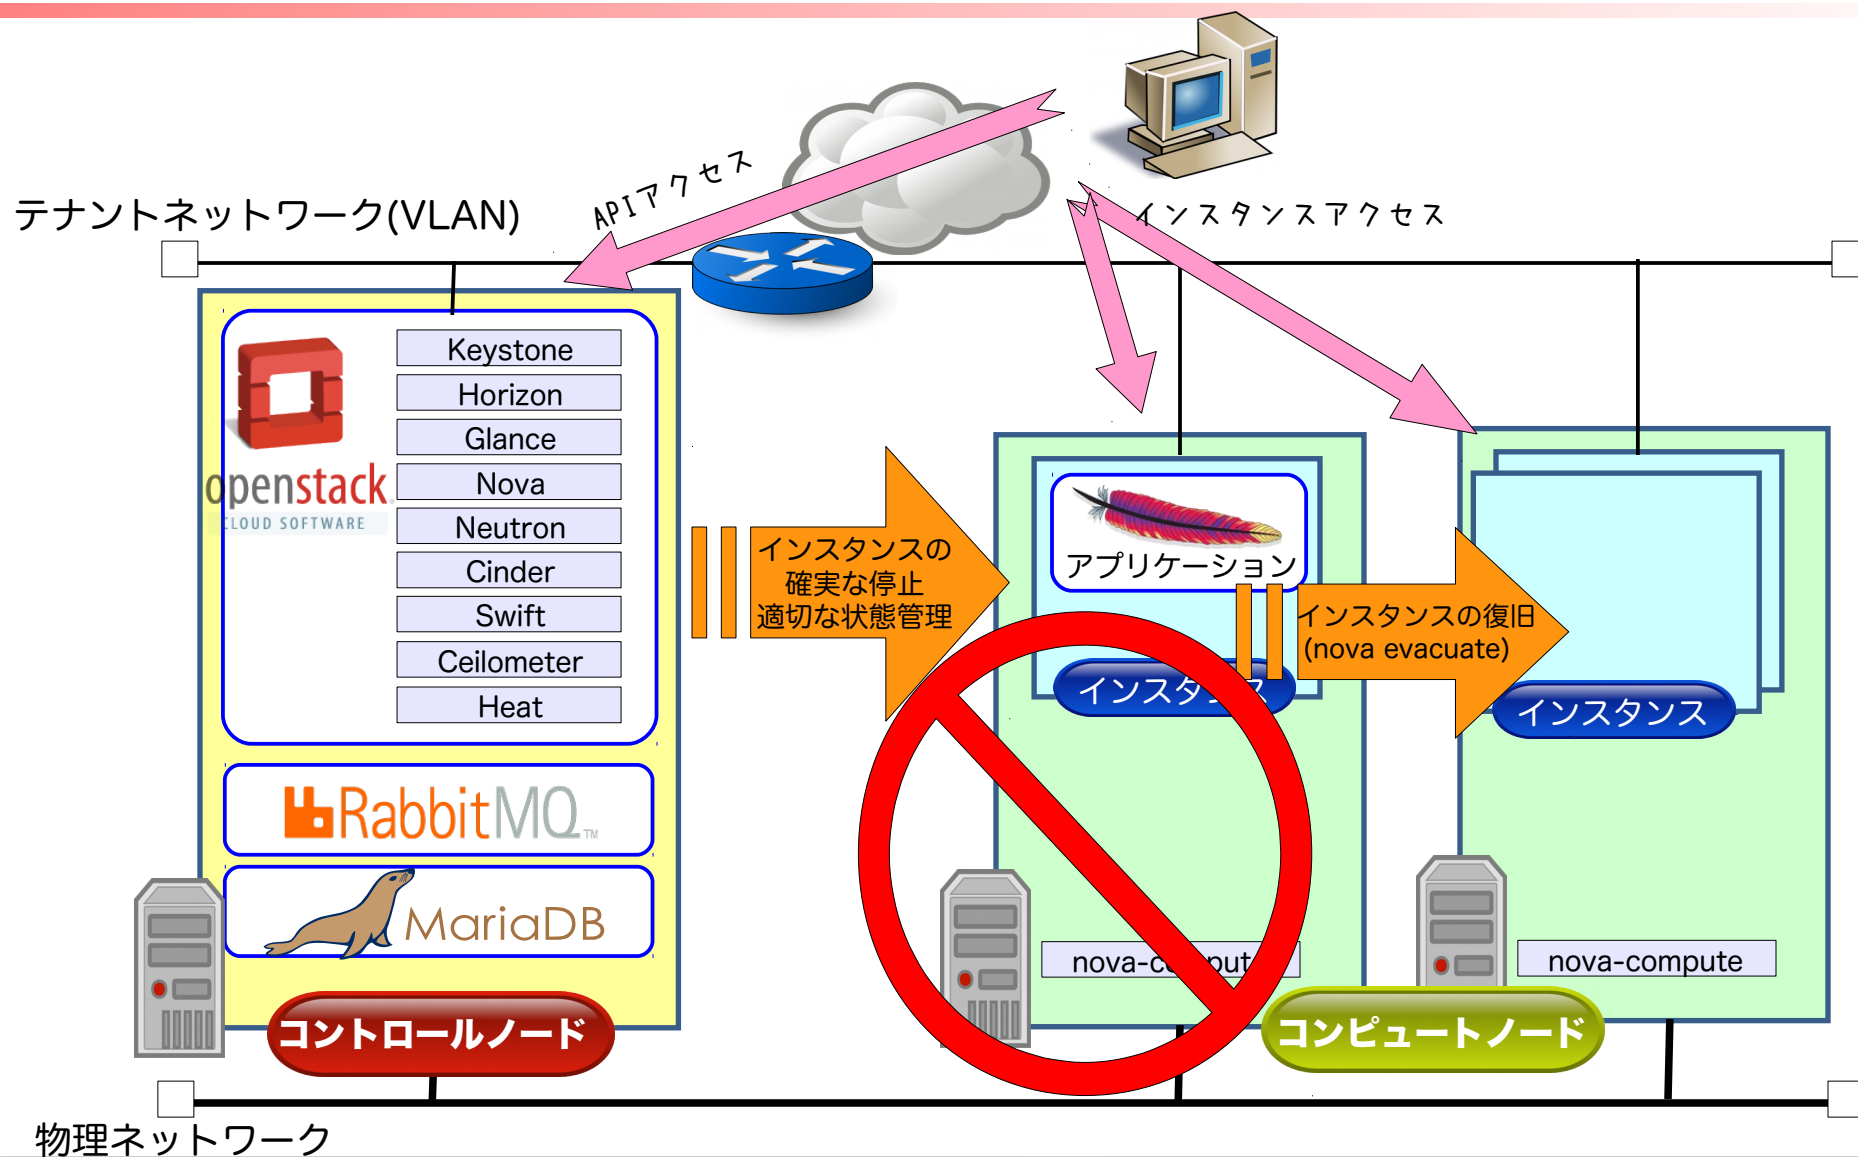
# 雲の下では…



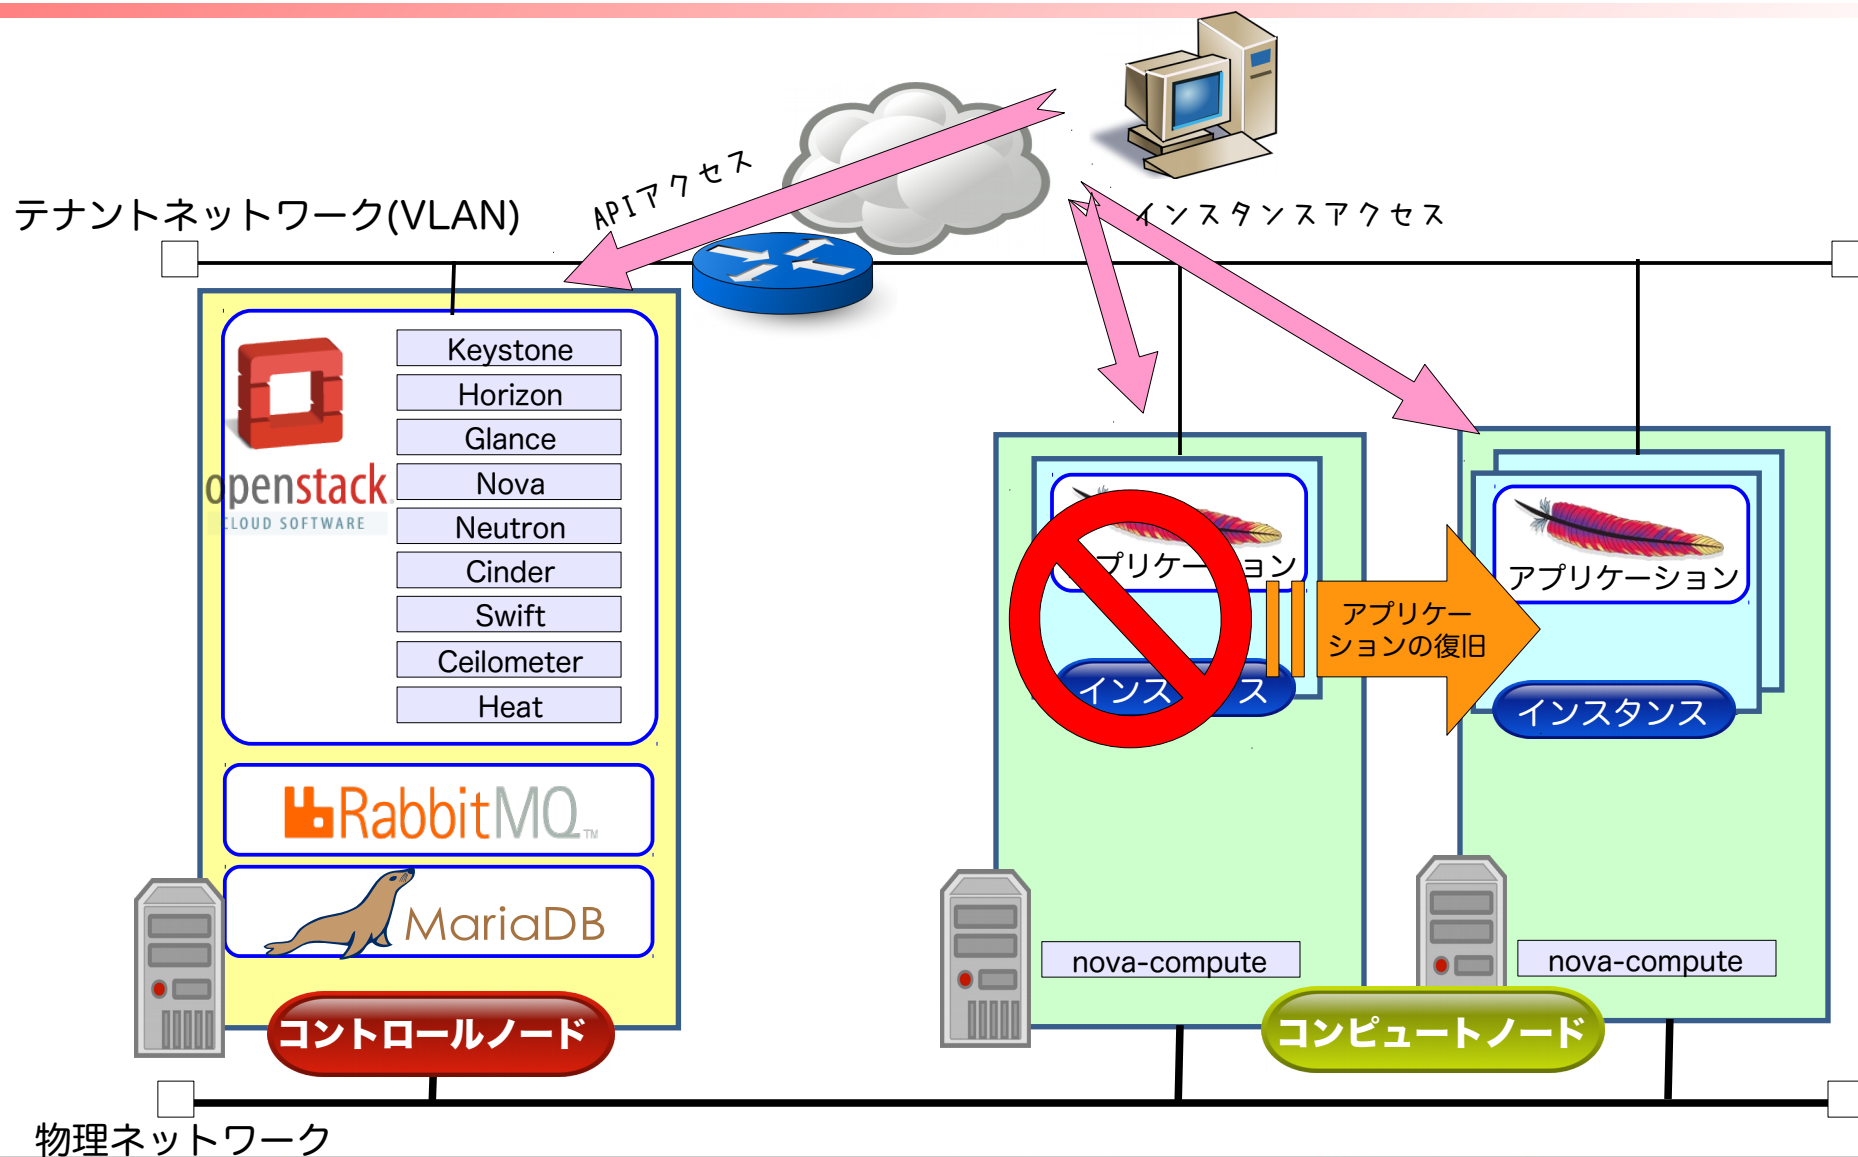
# コントロールノードの故障



# コンピュータノードの故障



# アプリケーションの故障





クラウド時代にHAクラスタなんて  
いるのお??



当然必要よ!

## ■ コントロールノードHA

- コントロールノードの物理故障・通信断
- 各OpenStackサービスプロセス・データベースサーバ・メッセージキューのソフトウェア故障

クラウド提供者  
(基盤管理者)  
による管理

## ■ コンピュートノードHA

- コンピュートノードの物理故障・通信断
- インスタンスのソフトウェア故障

## ■ アプリケーションHA

- インスタンスのソフトウェア故障
- テナントユーザのサービス(アプリケーション)故障

クラウドユーザ  
(テナント)  
による管理



## ■ クラウド提供者(基盤管理者)にとっては…

- クラウドユーザに対するOpenStackサービスの可用性確保
  - 従来通りの物理環境での HAクラスタが必要
- インスタンスの可用性確保
  - 従来の HA クラスタのさらなる応用が必要

## ■ クラウドユーザ(テナント)にとっては…

- クラウド提供者(基盤管理者)が可用性を確保しているからこそ安心して利用が可能
- 自分のサービス (アプリケーション)の可用性は自分で確保する必要あり
  - クラウド上でのHAクラスタ構成
  - クラウド特有の方式 (Ceilometer / Heat / Senlin 等)

# 主なディストリビューションのHA方式

ディストリビューション	構築方式	HAクラスタソフトウェア	コントロールノードHA	コンピュータノードHA	データベース冗長化方式	補足
Openstack.org (upstream)	手動	Pacemaker + Corosync	△	—	Galera	<ul style="list-style-type: none"><li>公式ドキュメントでは要件・概念と手順の断片が示されているのみ。</li><li>具体的な設定・構築手順等は独自に設計する必要あり。</li><li>2016年10月時点で日々更新中</li></ul>
Red Hat OpenStack Platform 8 (RH OSP)	director (Triple O)	Pacemaker + Corosync	○	○	Galera / MariaDB	<ul style="list-style-type: none"><li>コントロールノード構成は3ノード以上</li><li>全てのOpenStackサービスが同居する構成前提</li><li>Neutron はL3HA設定によるActive/Active構成</li></ul>
SUSE OpenStack Cloud 6	Crowbar + barclamp	Pacemaker + Corosync	○	○	PostgreSQL + DRBD	<ul style="list-style-type: none"><li>コントロールノード構成はDBサーバのみ2ノード、他のOpenStackサービスは3ノード以上</li><li>Neutron はスクリプト方式(ha-tools)によるHA方式</li></ul>
Ubuntu	MAAS + juju	Pacemaker + Corosync	○	—	Percona XtraDB Cluster	
Mirantis	Fuel	Pacemaker + Corosync	○	—	Galera / MySQL	

※主に Liberty ベース時点での情報



クラウド時代にHAクラスタなんて  
いるのお??

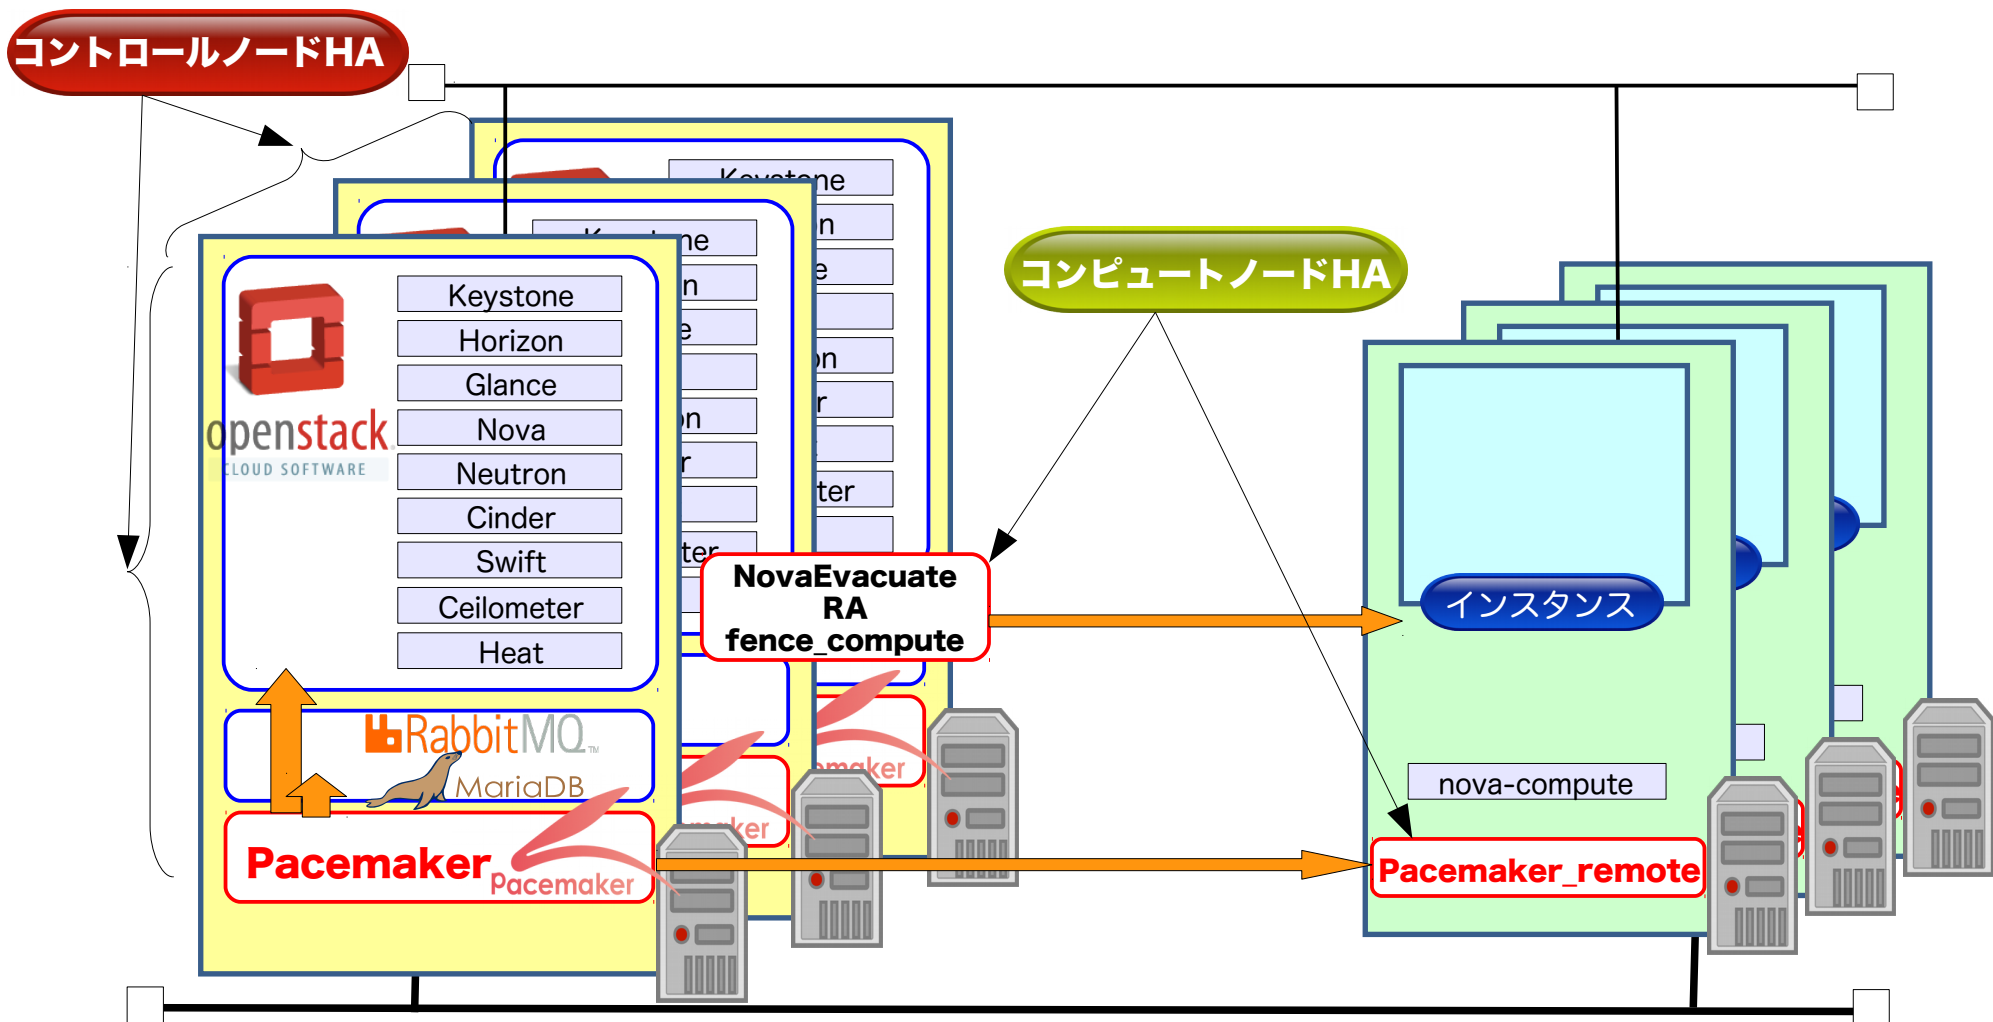


当然必要よ!

OpenStackクラウド基盤の高可用化にも  
Pacemakerは使われてるの!

- Pacemakerとは
- OpenStack におけるHAの必要性
- Red Hat OpenStack Platform でのHA構成例
- OpenStack HA の今後の動向

# Red Hat OpenStack Platform 8 のHA構成概要



※ストレージノードは省略

## ■ コントロールノードHA

- ノード構成: 3ノード以上
  - クォーラム制御(多数決制御)のため
- すべてのOpenStackサービス・データベースサーバ等が同居する構成が前提
  - ストレージノードのみ分離可能
  - 本資料では説明の単純化のためNFSサーバを使用している

## ■ コンピュートノードHA

- Pacemaker\_remote機能, NovaEvacuate RA による実装方式

## ■ OSP director (Triple O) によるHA構成の自動構築

- 実際にサービスを提供するOpenStack環境(オーバークラウド)を、構築用の別のマシン(アンダークラウド)から自動構築する
- コントロールノードHAは自動構築が可能
- コンピュートノードHAについては自動構築対象外
  - ドキュメントに手動構築手順あり

# RH OSP 8 のHA環境構築の流れ

## アンダークラウド

① インストール・設定  
(アンダークラウド構築)

OSP director

② テンプレートカスタマイズ  
(オーバークラウド設定)

Heat templates

③ オーバークラウド作成  
コマンド実行

openstack  
overcloud deploy

④ PXEブート・構築実行



overcloud-full.qnow2

⑤ 作成後の追加設定  
(フェンシング設定追加)

## オーバークラウド



Keystone

Horizon

Glance

Nova

Neutron

Cinder

Swift

Ceilometer

Heat



Pacemaker

コントロールノード

インスタンス

nova-compute

コンピューターノード

※ストレージノードは省略

## ■ オーバークラウド作成コマンド オプション例

```
[stack@bl460g9n6 ~]$ openstack overcloud deploy
--templates
-e /usr/share/openstack-tripleo-heat-templates/environments/network-isolation.yaml
-e /usr/share/openstack-tripleo-heat-templates/environments/network-management.yaml
-e ~/templates/network-environment.yaml
-e ~/templates/storage-environment.yaml
--control-scale 3
--compute-scale 1
--control-flavor control
--compute-flavor compute
--ntp-server 192.168.28.80
--neutron-network-type vxlan
--neutron-tunnel-types vxlan
```

## ■ ポイント

- コントロールノードのノード数を指定する
- HA構成のためには 3ノード以上、奇数ノード数が必要
  - `--control-scale 1` : 冗長化なし
  - `--control-scale 2` : 冗長化なし(1ノード故障時にサービス停止)
    - 偶数ノード数では半数のノードが故障した時点でサービス停止となる (クォーラム制御)
  - `--control-scale 3` : 冗長化あり



## ■ オーバークラウド作成後の追加設定

### □ コントローラノードのフェンシング設定追加

```
$ sudo pcs stonith create my-ipmilan-for-controller01 fence_ipmilan pcmk_host_list=overcloud-controller-0 ipaddr=192.168.28.43 login=USERID passwd=PASSWORD lanplus=1 op monitor interval=60s
$ sudo pcs constraint location my-ipmilan-for-controller01 avoids overcloud-controller-0
$ sudo pcs stonith create my-ipmilan-for-controller02 fence_ipmilan pcmk_host_list=overcloud-controller-1 ipaddr=192.168.28.42 login=USERID passwd=PASSWORD lanplus=1 op monitor interval=60s
$ sudo pcs constraint location my-ipmilan-for-controller02 avoids overcloud-controller-1
$ sudo pcs stonith create my-ipmilan-for-controller03 fence_ipmilan pcmk_host_list=overcloud-controller-2 ipaddr=192.168.28.41 login=USERID passwd=PASSWORD lanplus=1 op monitor interval=60s
$ sudo pcs constraint location my-ipmilan-for-controller03 avoids overcloud-controller-2
$ sudo pcs property set stonith-enabled=true
```

## ■ ポイント

- フェンシング機能(STONITH機能)設定はハードウェアに依存するため、環境に合わせ手動で設定追加を行う。
  - 一般的には IPMI 経由による強制電源断
- フェンシング機能はデータベース・メッセージキューのデータ整合性を保障するために非常に重要(スプリットブレインの防止)

# 何ができあがったの？

## ■ crm\_mon コマンドで見てみよう

- ❑ Pacemaker のリソース稼働状況を確認するコマンド
- ❑ 表示例: よくあるWeb・DBサーバの冗長構成の場合は…

```
2 Nodes configured
16 Resources configured

Online: [ pm01 pm02 ]

Full list of resources:

Resource Group: master-group
  filesystem      (ocf::heartbeat:Filesystem):      Started pm01
  apache (ocf::heartbeat:apache):                  Started pm01
  vip-master      (ocf::heartbeat:IPaddr2):          Started pm01
  vip-rep         (ocf::heartbeat:IPaddr2):          Started pm01
Resource Group: grpStonith1
  prmStonith1-1   (stonith:external/stonith-helper): Started pm02
  prmStonith1-2   (stonith:external/ipmi):            Started pm02
Resource Group: grpStonith2
  prmStonith2-1   (stonith:external/stonith-helper): Started pm01
  prmStonith2-2   (stonith:external/ipmi):            Started pm01
Master/Slave Set: msPostgresql [pgsql]
  Masters: [ pm01 ]
  Slaves:  [ pm02 ]
Master/Slave Set: msDrbd [drbd]
  Masters: [ pm01 ]
  Slaves:  [ pm02 ]
Clone Set: clnPing [prmPing]
  Started: [ pm01 pm02 ]
Clone Set: clnDiskd1 [prmDiskd1]
  Started: [ pm01 pm02 ]
```

- ノード数: 2
- 稼働リソース数: 16

# RH OSP 8 でのcrm\_mon出力

3 nodes and 118 resources configured

Online: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]

Full list of resources:

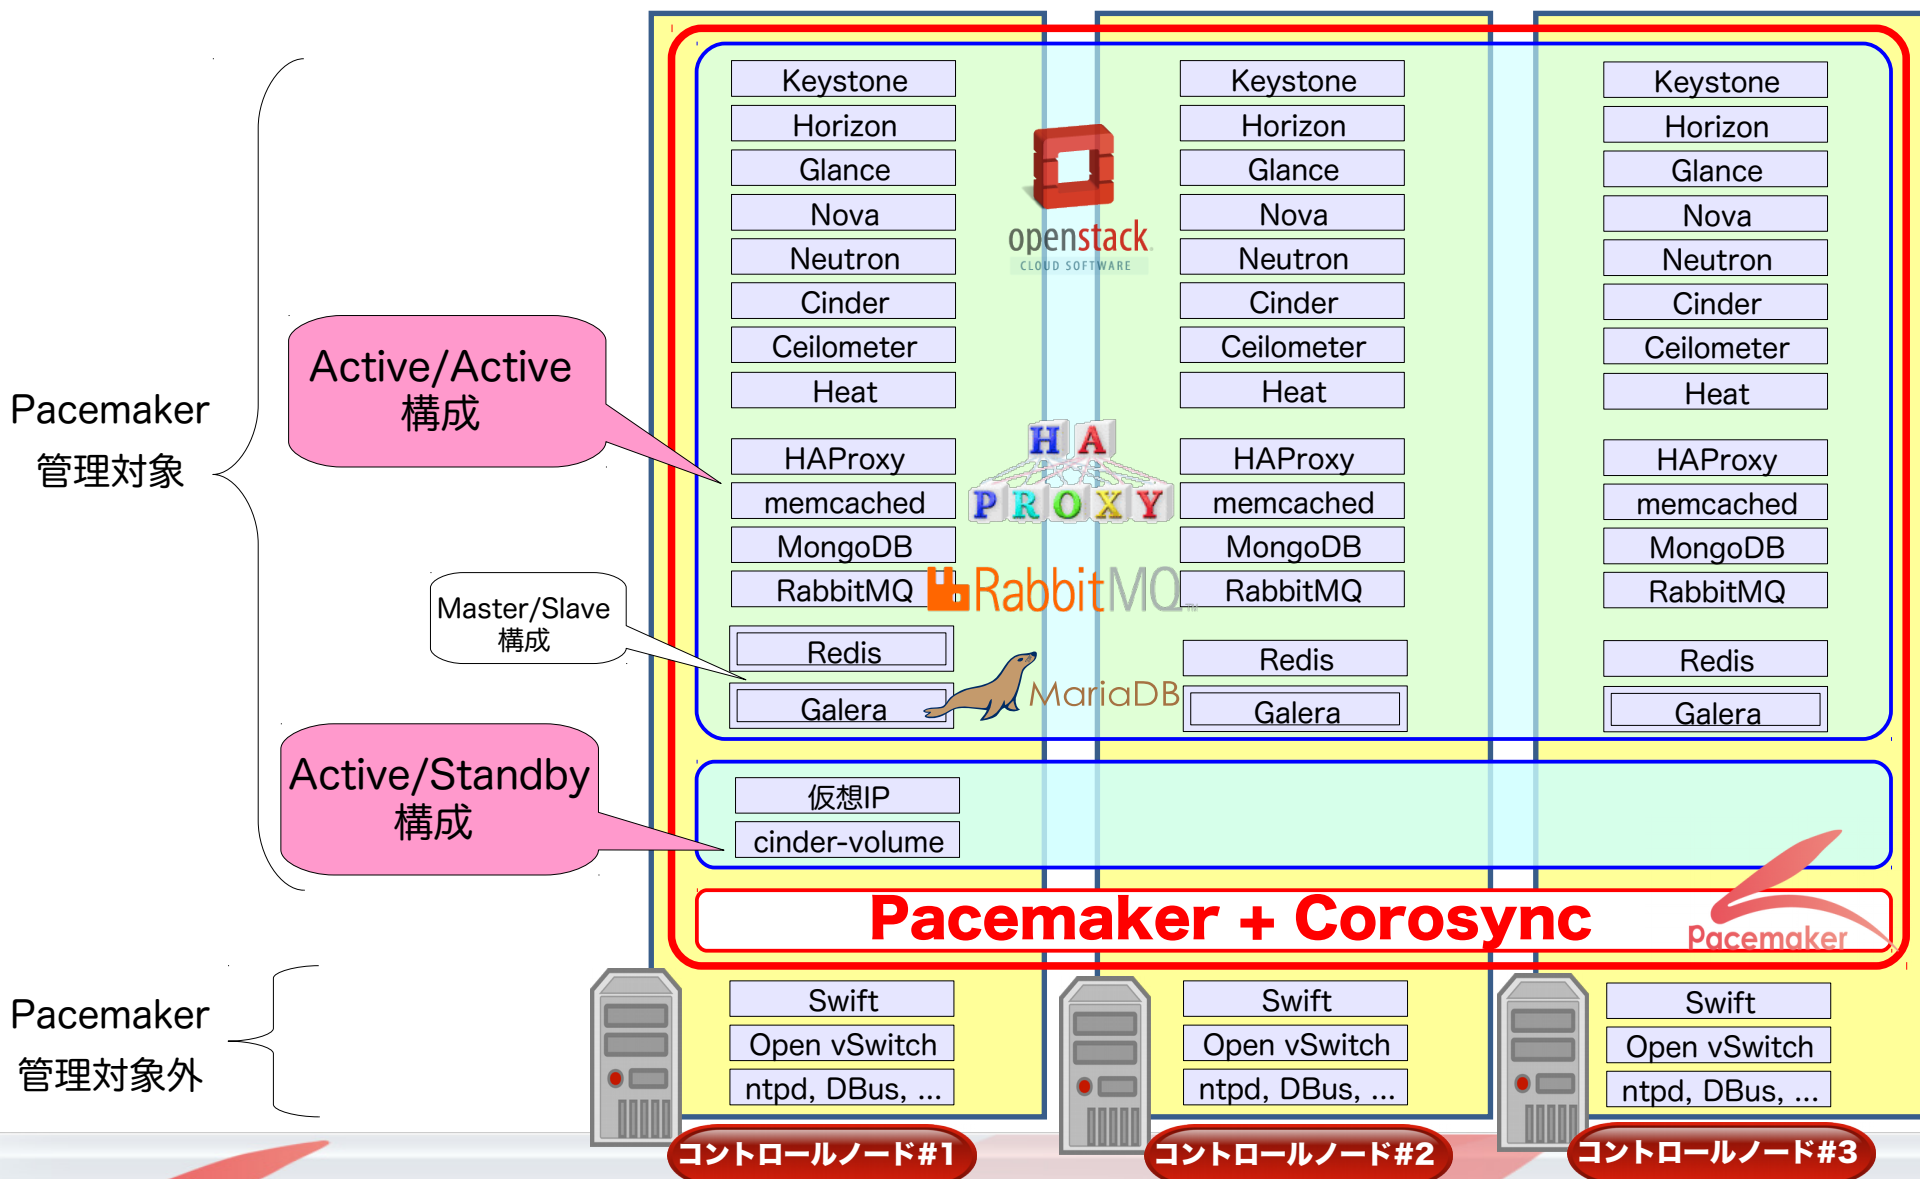
```
Clone Set: haproxy-clone [haproxy]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
ip-172.18.0.10 (ocf::heartbeat:IPaddr2): Started overcloud-controller-0
ip-172.16.0.11 (ocf::heartbeat:IPaddr2): Started overcloud-controller-1
ip-172.16.0.10 (ocf::heartbeat:IPaddr2): Started overcloud-controller-2
ip-172.19.0.10 (ocf::heartbeat:IPaddr2): Started overcloud-controller-0
ip-192.0.2.26 (ocf::heartbeat:IPaddr2): Started overcloud-controller-1
ip-10.1.1.10 (ocf::heartbeat:IPaddr2): Started overcloud-controller-2
Master/Slave Set: redis-master [redis]
  Masters: [ overcloud-controller-1 ]
  Slaves: [ overcloud-controller-0 overcloud-controller-2 ]
Master/Slave Set: galera-master [galera]
  Masters: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: mongod-clone [mongod]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: rabbitmq-clone [rabbitmq]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: memcached-clone [memcached]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: fs-varlibglanceimages-clone [fs-varlibglanceimages]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-nova-scheduler-clone [openstack-nova-scheduler]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: neutron-l3-agent-clone [neutron-l3-agent]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-ceilometer-alarm-notifier-clone [openstack-ceilometer-alarm-notifier]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-heat-engine-clone [openstack-heat-engine]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-ceilometer-api-clone [openstack-ceilometer-api]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: neutron-metadata-agent-clone [neutron-metadata-agent]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: neutron-ovs-cleanup-clone [neutron-ovs-cleanup]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: neutron-netns-cleanup-clone [neutron-netns-cleanup]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-heat-api-clone [openstack-heat-api]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-cinder-scheduler-clone [openstack-cinder-scheduler]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
```

■ ノード数: 3  
■ 稼働リソース数: 118

なるほど、わからん...

```
Clone Set: openstack-nova-api-clone [openstack-nova-api]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-heat-api-cloudwatch-clone [openstack-heat-api-cloudwatch]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-ceilometer-collector-clone [openstack-ceilometer-collector]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-keystone-clone [openstack-keystone]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-nova-consoleauth-clone [openstack-nova-consoleauth]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-glance-registry-clone [openstack-glance-registry]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-ceilometer-notification-clone [openstack-ceilometer-notification]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-cinder-api-clone [openstack-cinder-api]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-neutron-dhcp-agent-clone [openstack-neutron-dhcp-agent]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-glance-api-clone [openstack-glance-api]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-neutron-openvswitch-agent-clone [openstack-neutron-openvswitch-agent]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-nova-novncproxy-clone [openstack-nova-novncproxy]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: delay-clone [delay]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: neutron-server-clone [neutron-server]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: httpd-clone [httpd]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-ceilometer-central-clone [openstack-ceilometer-central]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-ceilometer-alarm-evaluator-clone [openstack-ceilometer-alarm-evaluator]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
Clone Set: openstack-heat-api-cfn-clone [openstack-heat-api-cfn]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
openstack-cinder-volume (systemd:openstack-cinder-volume): Started overcloud-controller-0
Clone Set: openstack-nova-conductor-clone [openstack-nova-conductor]
  Started: [ overcloud-controller-0 overcloud-controller-1 overcloud-controller-2 ]
my-ipmilan-for-controller01 (stonith:fence_ipmilan): Started overcloud-controller-1
my-ipmilan-for-controller02 (stonith:fence_ipmilan): Started overcloud-controller-2
my-ipmilan-for-controller03 (stonith:fence_ipmilan): Started overcloud-controller-0
```

# RH OSP 8 におけるPacemakerリソース構成



## ■ OpenStack関連サービス: 29リソース

- ほぼ全てActive/Active構成
  - 全ノードで起動し、HAProxyにより負荷分散
  - systemd経由による故障監視。プロセス故障のみ検知可能
- cinder-volume のみ Active/Standby 構成
  - cinder-volume の制約による(現時点では stateful サービスであり Active/Active構成不可)
- データベース、RabbitMQサービス起動完了後に起動するよう順序依存関係を制御

## ■ データベース・RabbitMQサービス: 5リソース

- Galera, RabbitMQ 独自の実装によりミラーリング対応・Active/Active構成が可能
  - ただし実際に読み書きを行うノードはHAproxy設定により1ノードのみに制限
- クラスタとしての起動手順をリソースエージェント(OCF RA)により制御

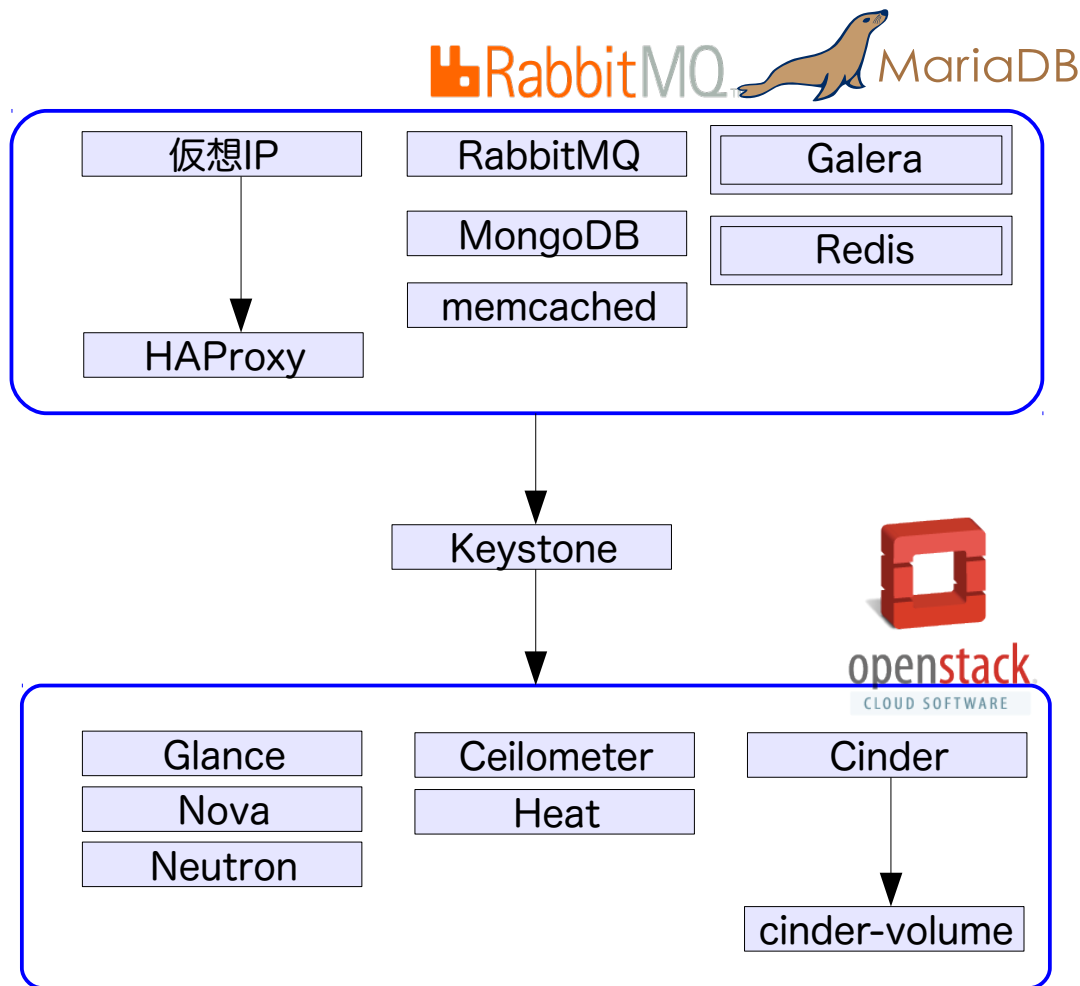
## ■ 仮想IP、HAProxy、他: 12リソース

- ノード故障時の切替、負荷分散
- STONITHエージェント等(図には未記載)

※Active/Activeリソースは3ノード全てで起動するため、crm\_monで表示されるリソース数の合計は118リソースとなる。詳細内訳は省略

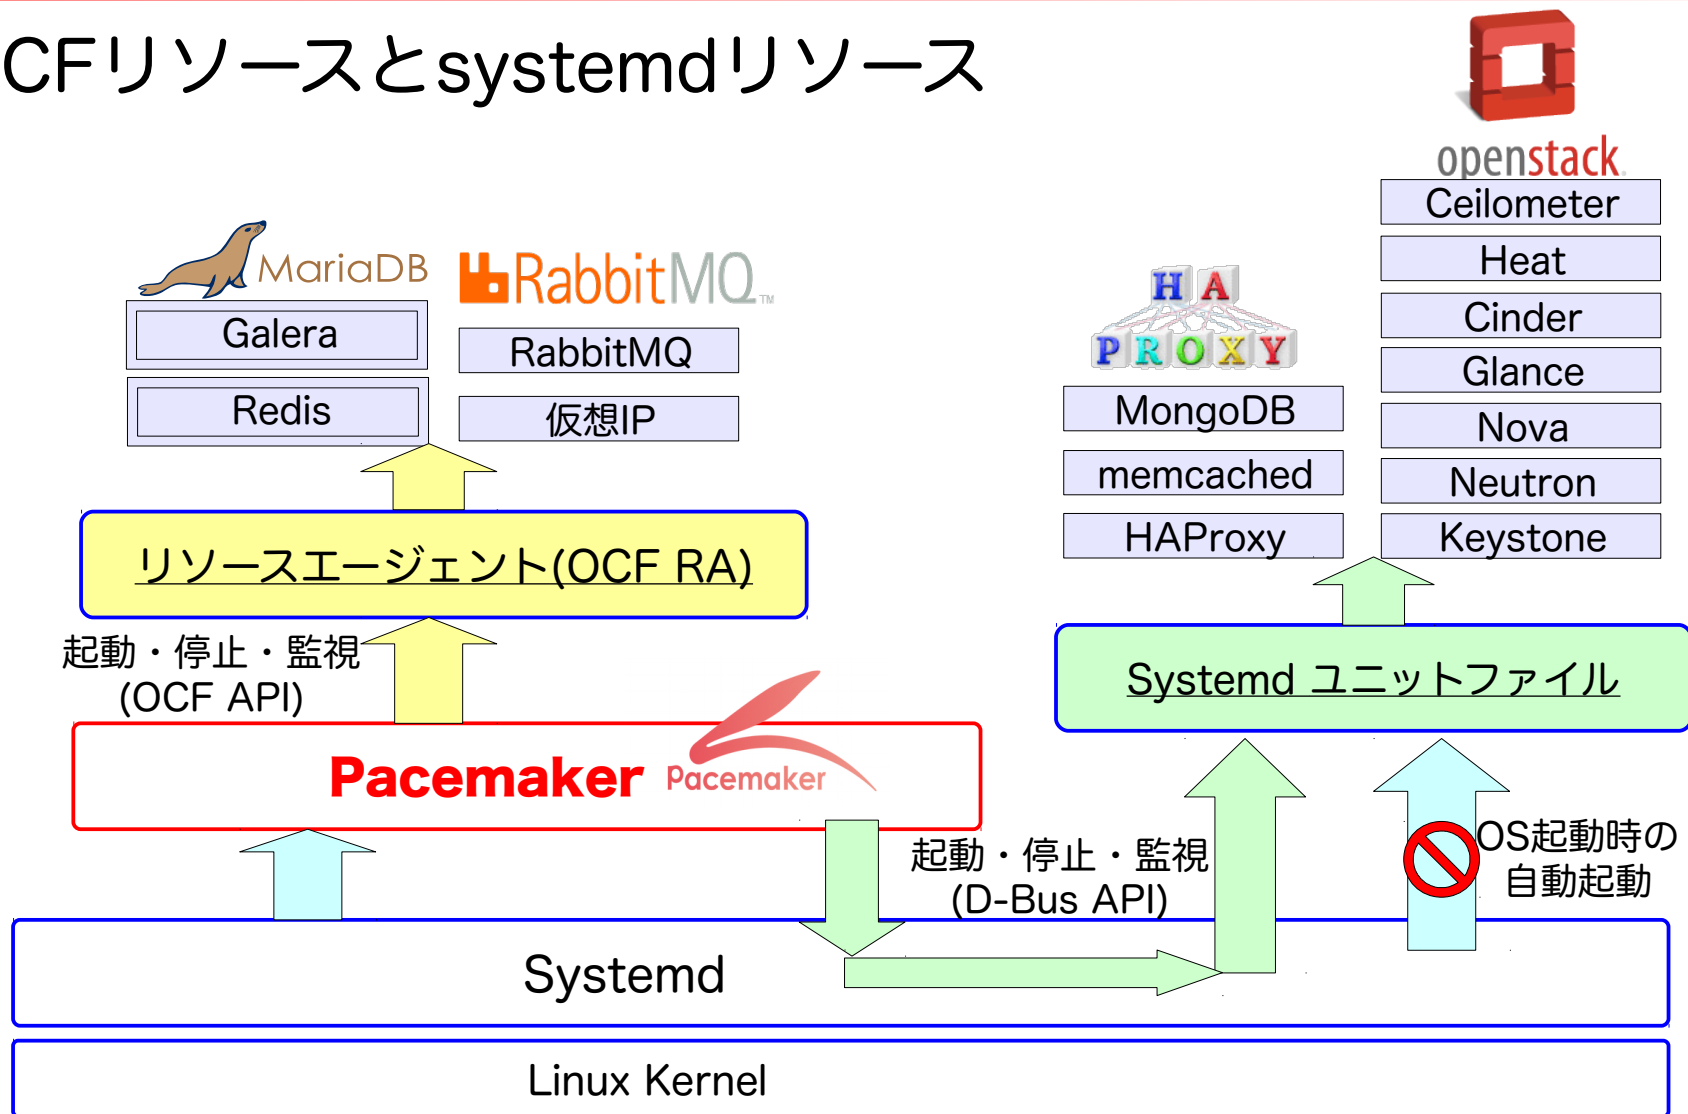
## ■ Pacemakerの制御により、以下の順序で起動される

- (1) 仮想IP、データベース、メッセージキューの起動
- (2) 仮想IP起動完了後 HAProxy起動
- (3) (1)(2)全て起動完了後、Keystone起動
- (4) Keystone起動完了後、各OpenStackサービス起動



# Pacemakerのリソース制御方法

## ■ OCFリソースとsystemdリソース





## ■ OpenStack関連サービス

### □ swift

- OS起動と同時に起動、systemd による監視・再起動
- RH OSP における設計指針は不明だが、swift は他のサービスに比較して独立性が高く systemd による再起動のみで十分と判断したと推測

## ■ Open vSwitch

### □ 現状 systemd では故障検知不可能

- systemctl status はプロセス故障時にも OK を返却する
- したがってPacemakerのリソースに追加しても故障検知はできない
- 意図した仕様なのか不具合なのかは不明

### □ 監視が必要な場合は個別に監視処理を追加する必要あり

- 独自にリソースエージェントの作成、運用監視システム等による監視など

## ■ 各種OSサービス

### □ ntpd, D-Bus, 他

- 必要に応じて運用監視システム等により監視
- 物理環境のHAクラスタにおいても通常は Pacemaker では管理していない



## ■ 故障検知と自動フェイルオーバーによるダウンタイム短縮

### □ 切替時間目安:

- 約70～80秒程度(負荷なし、ノード電源断～dashboard画面アクセス再開まで)
  - 内訳: Pacemaker内部処理 30～40秒程度 + OpenStackサービス再開処理 30～40秒程度
- 故障箇所・故障タイミング・負荷等条件により大きく変わるのであくまで目安で

### □ フェンシング(STONITH)によるデータ整合性の担保も含む

- Galera, RabbitMQ 単体だけで担保できるのか?
- 全ての故障、全てのネットワーク構成、全ての故障タイミング、ネットワーク一時分断・復活 etc...

## ■ 起動手順・依存関係の自動化による運用手順簡易化

### □ Q. そんなん systemd があるやん?

### □ A. systemdだけではできないこともあるんやよ

- Galera, RabbitMQ のクラスタ構成に必要なノード別の起動手順
- 起動「完了」まで待ってからの次の起動
- ノードをまたぐ順序関係

- Pacemakerとは
- OpenStack におけるHAの必要性
- Red Hat OpenStack Platform でのHA構成例
- OpenStack HA の今後の動向

- OpenStackサービスはPacemaker管理外で良いんじゃない？
  - という方向で今開発コミュニティは動いてます

# これが...

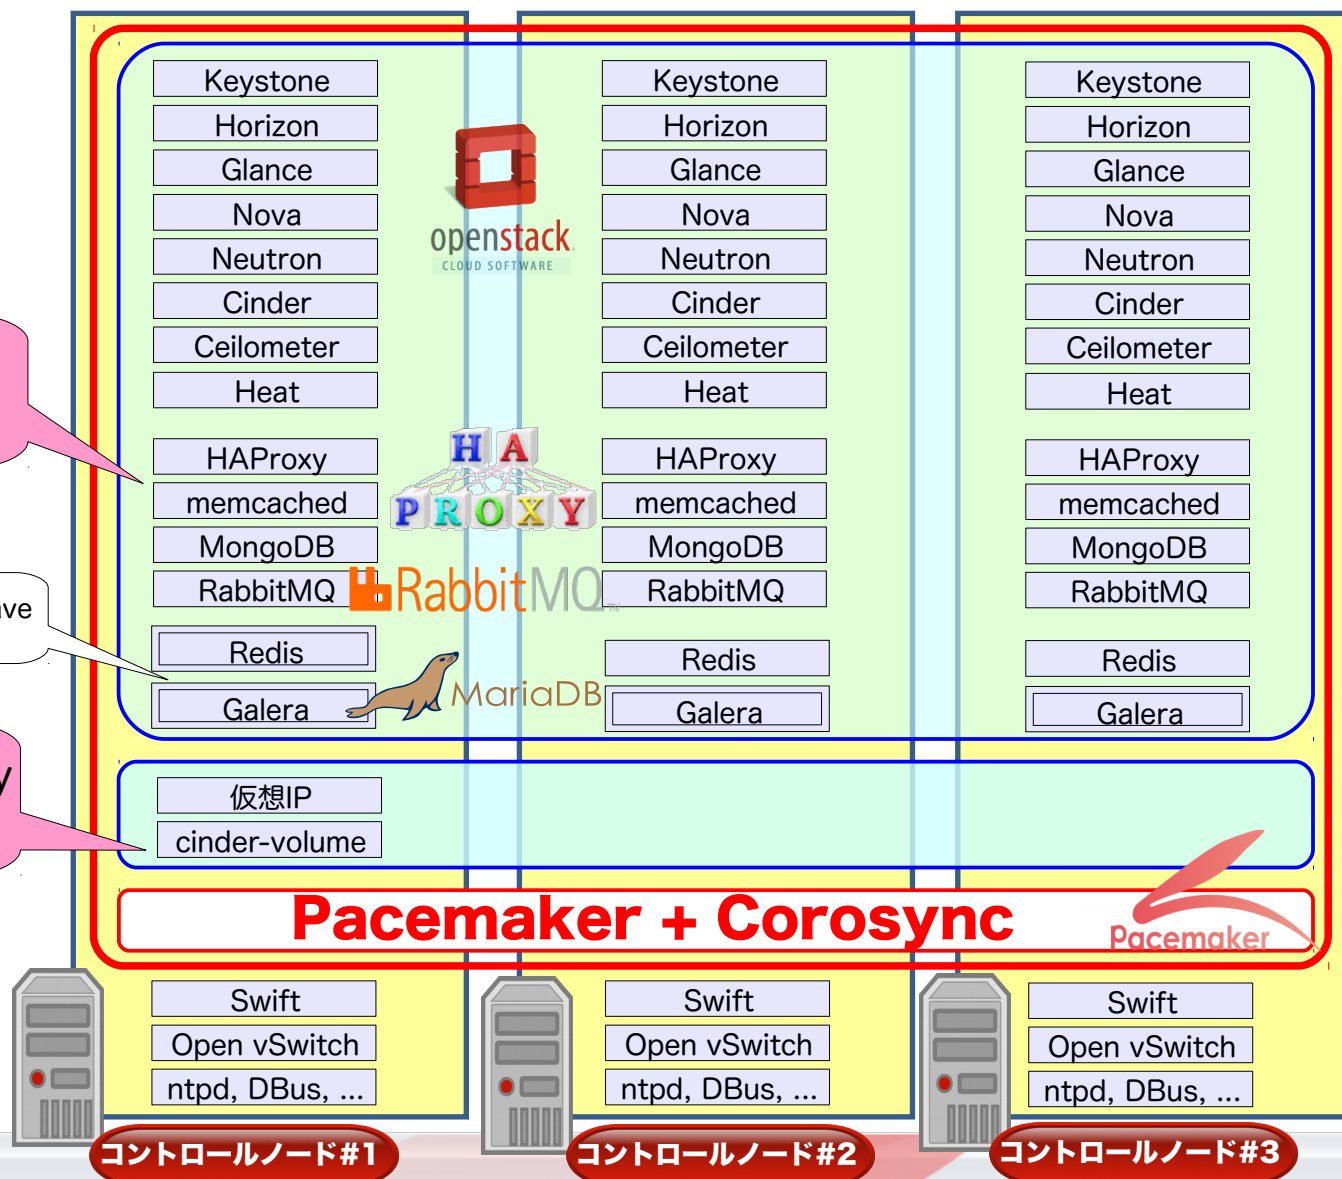
Pacemaker  
管理対象

Active/Active  
構成

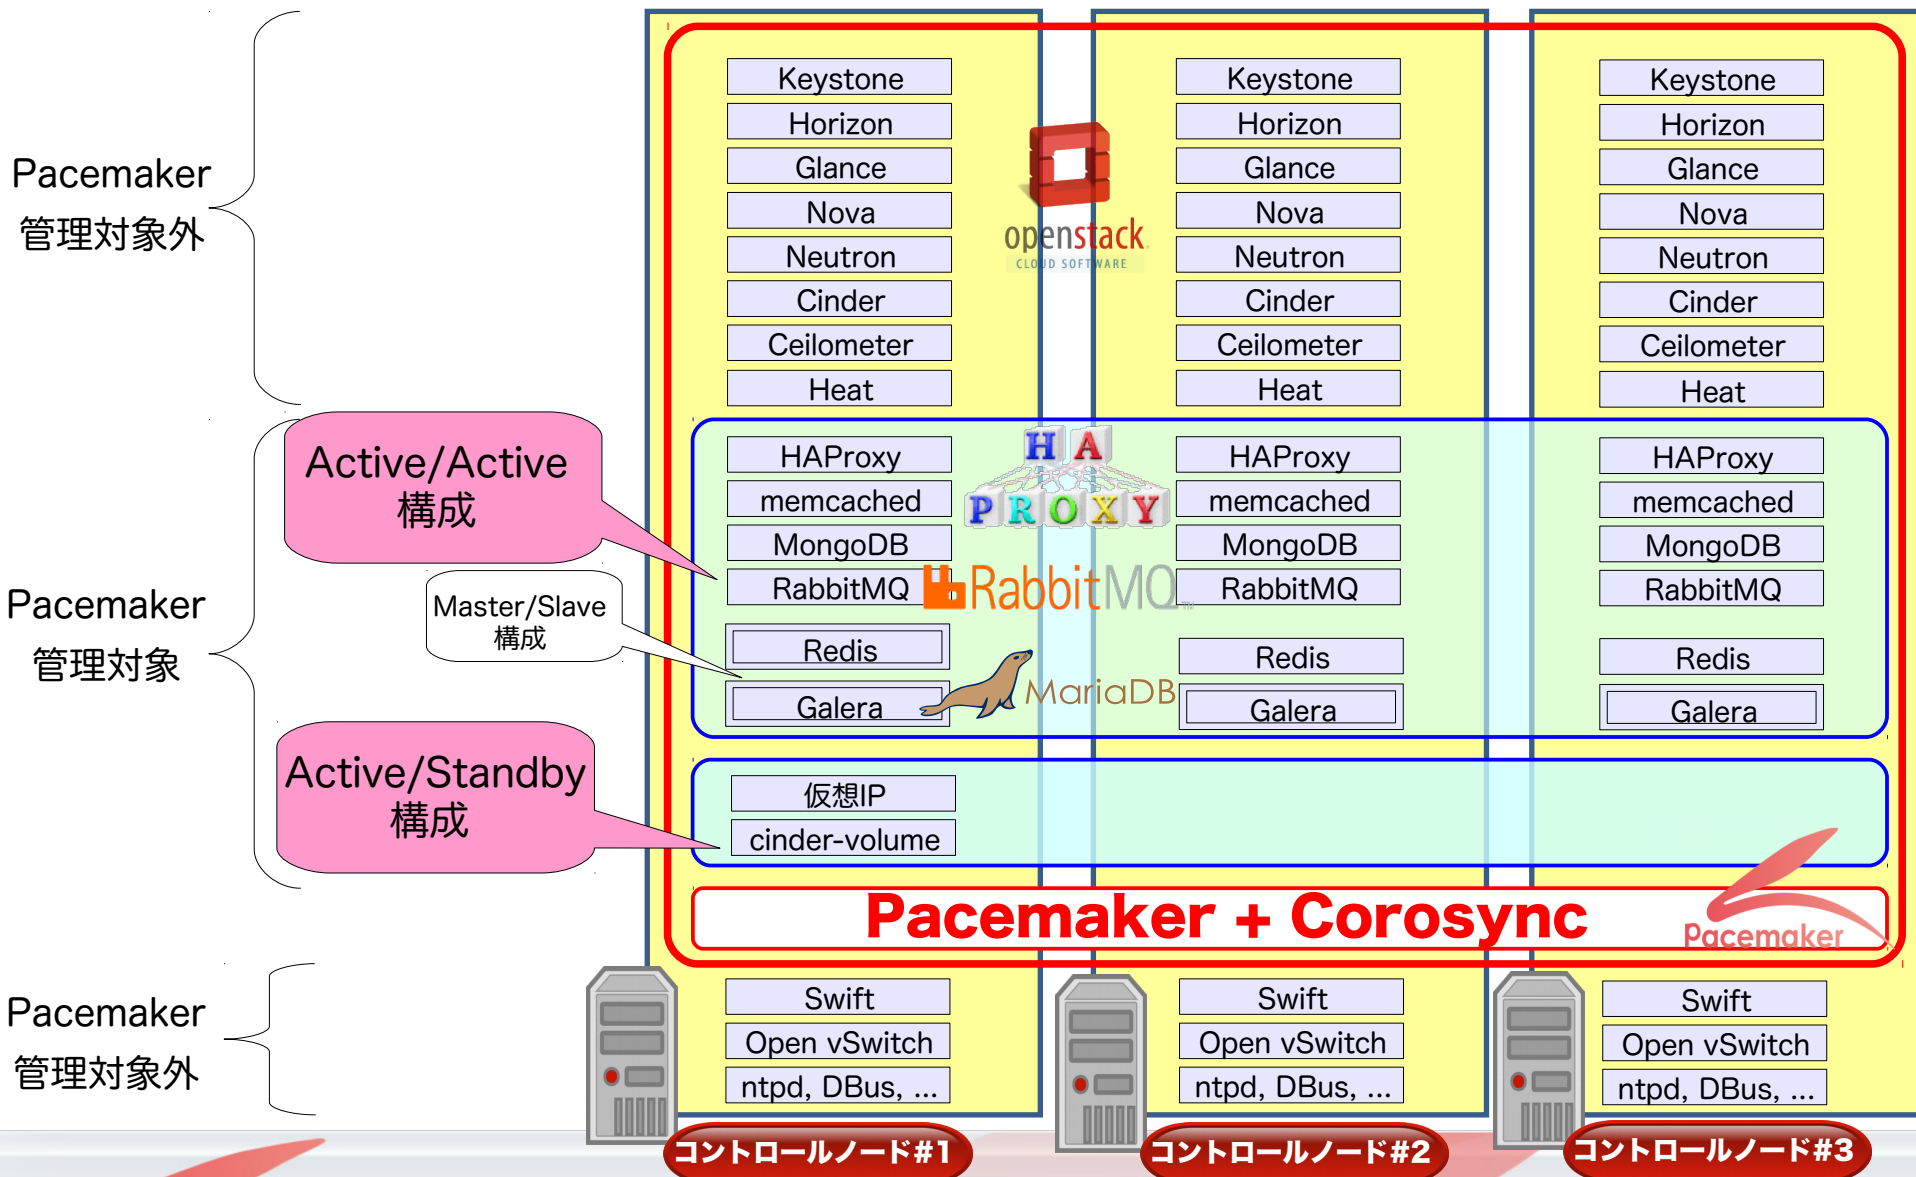
Master/Slave  
構成

Active/Standby  
構成

Pacemaker  
管理対象外



# こうなる! (?)



## ■ OpenStackサービスはPacemaker管理外とする方向

### □ ACT/SBYリソースのみ管理対象とする

- cinder-volume、他にもあれば (neutron-lbaas-agent ?)
- cinder-volume のACT/ACT対応は現在議論中、対応完了すれば管理外とする

### □ ただし全てのOpenStackサービスは起動順序に依存しないことが前提

- データベースやメッセージキュー等の依存サービスがダウンしても、フェイルオーバー後に自動的に復旧できること
- 開発コミュニティにて検証中

### □ RH OSPでは…

- Mitakaベース(RH OSP 9)では keystone が管理外となっている
- おそらく Newtonベースの RH OSP 以降で大きく変更されるのでは

## ■ OpenStackサービスはPacemaker管理外とする方向

## ■ 開発コミュニティでは異論もあり、議論継続中

### □ 管理すべきだよ派

- systemdのプロセス監視だけでは不十分、OCF RA等でサービス監視もやりたい
- OpenStackサービスはSTONITH無くてホントに大丈夫なん？

### □ 管理しなくてもいいよ派

- サービス監視は運用監視ツール(Nagiosとか)でやればいいんじゃないの
- 起動順序の依存関係はOpenStackサービス側で解決すればいいよね
- それよりもHeatテンプレートの維持管理とかバージョンアップを楽にしようよ

## ■ 現状以下の3方式があり、これから統合されていく予定

### □ NovaEvacuate RA (Red Hat, SUSE)

- 商用サポート提供済み、ただし故障対応範囲に制約あり

### □ Masakari (NTT)

- 故障対応範囲が充実、ただしPacemakerとの連携に向上の余地あり

### □ Mistral (Intel)

- OpenStack全体のアーキテクチャとして望ましい、ただし現状試験実装レベル

## ■ 現時点での見込み

### □ Mistral のワークフローベースにMasakariの機能を統合していく方針

	NovaEvacuate RA	Masakari	Mistral
HA対象インスタンスのタグ管理	○	○	○
故障時アクションのカスタマイズ	—	—	予定あり
自己監視	○	○	実装中
インスタンス故障監視	—	○	予定あり
force_down API対応	○	—	予定あり
nova-compute故障対応	—	○	予定あり
並行実行	—	—	○

出典: <http://aspiers.github.io/openstack-summit-2016-austin-compute-ha/>



## ■ IRCミーティング

- 毎週月曜
- <https://wiki.openstack.org/wiki/Meetings/HATeamMeeting>

## ■ ドキュメント改善

- 公式HAドキュメントのメンテナがAndrew Beekhof 氏(Pacemaker開発者)に
  - <http://docs.openstack.org/ha-guide/>
  - 現在 (まさに今!) 随時更新中
- プロジェクト間活動に向けたユーザストーリー・仕様書

- Pacemakerをこれからもよろしくお願いします!

